

Master 1 Économétrie et Statistique
Parcours Économétrie Appliquée

MÉMOIRE

**Analyse et prévision de l'inflation dans le secteur de
l'énergie en France**

Réalisé par :

Amélie PIRES

Sous la direction de :

M. Olivier DARNÉ

IAE Nantes – Économie & Management

Année universitaire 2025–2026

Remerciements

Je tiens tout d'abord à remercier mon encadrant, Monsieur Olivier DARNÉ pour l'accompagnement et les enseignements suivis au cours de l'année, qui m'ont permis de mieux comprendre les méthodes de prévision appliquées aux séries temporelles.

Je remercie également l'ensemble des enseignants du Master 1 ECAP pour les connaissances transmises au cours de cette année universitaire, notamment en économétrie, en analyse de données et en économie appliquée. Je remercie aussi mes camarades pour l'entraide, les échanges et la bonne ambiance qui ont accompagné cette année.

Enfin, je remercie mes proches pour leur soutien tout au long de mes années d'études. Leurs encouragements, parfois directs et parfois plus indirects, m'ont aidée à poursuivre mon parcours et à arriver jusqu'à la réalisation de ce mémoire.

Résumé

Ce mémoire analyse la prévision de l'inflation énergétique en France à partir de variables liées aux marchés de l'énergie et aux matières premières. L'étude repose sur une base de données mensuelle couvrant la période allant de juillet 2015 à septembre 2025. L'inflation énergétique est calculée en glissement annuel à partir de l'indice des prix à la consommation de l'énergie. Les variables explicatives retenues sont le prix du pétrole Brent en euros, le prix du gaz naturel TTF et l'indice des matières premières importées hors énergie, auxquels sont ajoutées plusieurs variables retardées.

La méthodologie repose sur la comparaison de plusieurs modèles de prévision : un modèle naïf, un modèle ARIMA, une régression linéaire, un modèle ARMAX, plusieurs modèles Random Forest, ainsi qu'une Random Forest estimée en rolling window. Les performances sont évaluées sur une période de test allant de janvier 2022 à septembre 2025, marquée par le choc énergétique de 2022 puis par une phase de désinflation.

Les résultats montrent que le modèle naïf obtient les meilleures performances globales ce qui souligne la forte inertie de l'inflation énergétique calculée en glissement annuel. Parmi les modèles plus complexes, la Random Forest rolling window est la plus performante et améliore assez nettement la Random Forest classique. Le modèle RF2, qui est fondé sur les retards de l'inflation énergétique et du Brent, reste utile mais sa différence avec le modèle ARMAX n'est pas statistiquement significative selon le test de Diebold-Mariano.

Les résultats suggèrent donc qu'il est possible de prévoir partiellement l'inflation énergétique en France mais que cette prévision repose fortement sur la dynamique passée de la variable cible. Les prix du pétrole, du gaz naturel et des matières premières peuvent apporter une information complémentaire mais leur contribution dépend du contexte économique. La prévision reste donc sensible aux chocs économiques et géopolitiques, ce qui limite la capacité des modèles à anticiper les ruptures brutales observées sur les marchés de l'énergie.

Mots-clés : inflation énergétique, France, prévision, Random Forest, R.

Abstract

This thesis analyzes the forecasting of energy inflation in France using variables related to energy and commodity markets. The study is based on a monthly dataset covering the period from July 2015 to September 2025. Energy inflation is computed as the year-on-year growth rate of the energy consumer price index. The explanatory variables include the Brent oil price in euros, the natural gas TTF price, and the index of imported non-energy commodities, together with several lagged variables.

The methodology compares several forecasting models: a naïve model, an ARIMA model, a linear regression, an ARMAX model, several Random Forest models, and a Random Forest estimated using a rolling window approach. Forecasting performance is evaluated over the test period from January 2022 to September 2025, which includes the 2022 energy shock and the following disinflation period.

The results show that the naïve model achieves the best overall forecasting performance, highlighting the strong persistence of year-on-year energy inflation. Among the more complex models, the rolling window Random Forest performs best and clearly improves upon the standard Random Forest. The RF2 model, based on lagged energy inflation and lagged Brent prices, remains informative, but its difference from the ARMAX model is not statistically significant according to the Diebold-Mariano test.

The findings suggest that energy inflation in France can be partially forecast, but that forecasting performance relies strongly on the past dynamics of the target variable. Oil, natural gas and commodity prices may provide additional information, but their contribution depends on the economic context. Forecasting therefore remains sensitive to economic and geopolitical shocks, which limit the ability of models to anticipate sudden breaks in energy markets.

Keywords: energy inflation, France, forecasting, Random Forest, R.

Sommaire

Remerciements	2
Résumé	3
Abstract	4
Glossaire des sigles et indicateurs	6
Introduction	7
Partie 1 : Inflation énergétique et marchés de l'énergie	11
Partie 2 : Méthodologie de prévision	20
Partie 3 : Résultats empiriques et interprétation	31
Discussion	43
Conclusion	47
Bibliographie	49
Annexes	52
Table des matières	66

Glossaire des sigles et indicateurs

Tableau 1: Glossaire des sigles et indicateurs

Sigle	Signification
ARIMA	Modèle autorégressif intégré à moyenne mobile
ARX	Modèle autorégressif avec variables explicatives exogènes
ARMAX	Modèle autorégressif avec variables explicatives exogènes et erreurs de type ARMA
DM	Test de Diebold-Mariano, utilisé pour comparer les erreurs de prévision de deux modèles
IPC	Indice des prix à la consommation
INSEE	Institut national de la statistique et des études économiques
MAE	Mean Absolute Error, ou erreur absolue moyenne
MASE	Mean Absolute Scaled Error (erreur absolue moyenne mise à l'échelle)
RMSE	Root Mean Squared Error (racine de l'erreur quadratique moyenne)
R^2	Coefficient de détermination
RF	Random Forest
sMAPE	Symmetric Mean Absolute Percentage Error (erreur absolue moyenne symétrique en pourcentage)
TTF	Title Transfer Facility, prix de référence du gaz naturel en Europe

Introduction

Depuis le début des années 2020, l'inflation est redevenue une préoccupation centrale dans les économies européennes. Après plusieurs années marquées par une inflation relativement faible et stable, la reprise économique qui a suivi la crise sanitaire, les tensions sur les chaînes d'approvisionnement, la hausse du coût des matières premières et les déséquilibres sur les marchés internationaux ont contribué à une forte accélération des prix. Cette dynamique d'inflation a particulièrement touché les pays européens, qui sont très dépendants des importations d'énergie et exposés aux variations des prix du pétrole, du gaz naturel et de l'électricité. Dans ce contexte, l'énergie occupe une place particulière car elle constitue l'une des composantes les plus volatiles de l'indice des prix à la consommation. Cette évolution s'inscrit dans un contexte de tensions inflationnistes plus larges dans lequel la hausse des prix de l'énergie a fortement contribué aux dynamiques de prix observées en zone euro et en France (Banque de France, 2022 ; Banque de France, 2025).

L'inflation énergétique désigne l'évolution des prix des biens et services liés à l'énergie, notamment les carburants, le gaz, l'électricité, le fioul domestique ou encore certains produits énergétiques utilisés dans les transports et le logement. Elle se distingue de l'inflation globale par sa forte sensibilité aux chocs externes. Les prix de l'énergie peuvent en effet varier rapidement sous l'effet de tensions géopolitiques, de décisions prises par des pays producteurs, de contraintes d'approvisionnement, de variations du taux de change ou encore de changements dans la demande mondiale. Cette instabilité rend l'inflation énergétique particulièrement difficile à prévoir, d'autant plus que les mouvements des prix de marché ne se transmettent pas toujours immédiatement aux prix payés par les consommateurs.

L'intérêt économique du sujet est donc important. Une hausse des prix de l'énergie affecte directement les ménages à travers leurs dépenses de transport, de chauffage et d'électricité. Elle pèse donc sur le pouvoir d'achat et en particulier pour les ménages dont une part importante du budget est consacrée aux dépenses contraintes. Elle influence également les entreprises car l'énergie intervient dans les coûts de production, de transport et de distribution. Une augmentation du coût du pétrole, du gaz ou de l'électricité peut ainsi se diffuser à d'autres secteurs de l'économie, en renchérissant les biens intermédiaires, les services de transport ou encore certains produits manufacturés. L'inflation énergétique n'est alors pas seulement une partie isolée de l'inflation, elle peut également devenir un canal de transmission vers l'ensemble de l'économie. Les analyses de la Banque de France soulignent également que les chocs de prix peuvent se transmettre progressivement aux différentes composantes de l'inflation, avec des effets différenciés selon les secteurs et les prix considérés (Banque de France, 2022 ; Banque de France, 2025).

La période récente illustre particulièrement cette instabilité. À partir de 2021, les prix de l'énergie ont fortement augmenté dans un contexte de reprise post-Covid, de tensions sur les marchés internationaux et de crise énergétique européenne. L'invasion de l'Ukraine par la Russie en février 2022 a accentué ces tensions notamment sur le marché du gaz naturel, en raison de la dépendance européenne aux importations énergétiques. Dans le même temps, les

prix du pétrole Brent et les prix des matières premières ont connu des variations importantes, ce qui reflète les déséquilibres entre offre et demande ainsi que l'incertitude géopolitique. Ces évolutions ont contribué à rendre l'inflation énergétique particulièrement difficile à anticiper à l'aide de modèles statistiques classiques.

Les analyses de la Banque de France confirment le rôle central des prix de l'énergie dans la dynamique inflationniste récente. Dans ses projections de juin 2022, la Banque de France indique que la dynamique des prix de l'énergie constitue alors la première source de la forte hausse des prix en France. Les projections de septembre et décembre 2022 soulignent également que la montée des prix du gaz et de l'énergie sur les marchés internationaux représente un choc inflationniste majeur pour l'économie française. Et plus récemment, les travaux de la Banque de France sur le bouclier tarifaire montrent que les politiques publiques ont contribué à limiter la transmission de la hausse des prix de l'énergie aux prix payés par les ménages. Ces éléments renforcent l'intérêt d'étudier spécifiquement l'inflation énergétique et ses déterminants de marché (Banque de France, 2022a ; Banque de France, 2022b ; Banque de France, 2022c ; Banque de France, 2024).

Dans ce mémoire, l'inflation énergétique est étudiée dans le cas de la France. La variable cible correspond à l'inflation de l'énergie calculée en glissement annuel à partir de l'indice des prix à la consommation de l'énergie. Ce choix permet d'analyser l'évolution annuelle des prix énergétiques tout en conservant une fréquence mensuelle. L'étude repose sur une base de données mensuelle couvrant la période allant de juillet 2015 à septembre 2025. Cette période permet d'observer à la fois des phases relativement stables, la crise sanitaire, le choc énergétique de 2021-2022, puis la période de reflux progressif de l'inflation. Ce mémoire se limite volontairement au cas français et à un ensemble restreint de variables économiques directement liées aux prix de marché avec le prix du pétrole Brent en euros, le prix du gaz naturel TTF et l'indice des matières premières importées hors énergie.

Le choix de ces variables s'explique par leur lien économique direct avec l'inflation énergétique. Le Brent constitue une référence importante pour les prix pétroliers européens et influence notamment les carburants et certains coûts de transport. Le gaz naturel TTF représente un indicateur central du marché européen du gaz (dont les fluctuations ont joué un rôle majeur pendant la crise énergétique). Les matières premières importées hors énergie permettent quant à elles de prendre en compte un environnement plus large de tensions sur les prix importés. Afin de tenir compte des délais possibles de transmission entre les prix de marché et les prix à la consommation, plusieurs variables retardées sont également introduites. Les retards de l'inflation énergétique permettent de représenter l'inertie de la série tandis que les retards du Brent, du gaz et des matières premières permettent d'étudier leur effet différé sur l'inflation.

Ce travail s'inscrit dans la continuité des approches qui cherchent à prévoir l'inflation à partir de variables économiques et de modèles de séries temporelles. Les modèles économétriques classiques comme les modèles autorégressifs ou les modèles avec variables explicatives, permettent de représenter la dynamique temporelle de l'inflation et d'intégrer certains déterminants économiques. Néanmoins ces modèles reposent souvent sur des relations linéaires et peuvent avoir des difficultés à capter des effets de seuil, des interactions ou des ruptures brutales.

À l'inverse, les méthodes d'apprentissage automatique comme la Random Forest, introduite par Breiman (2001), permettent de prendre en compte des relations non linéaires et de hiérarchiser l'importance des variables explicatives. Des travaux récents montrent que les méthodes de machine learning peuvent améliorer les prévisions d'inflation dans des environnements riches en données même si leur performance dépend fortement du contexte et de la stabilité des relations économiques (Medeiros et al., 2021). Leur utilisation peut donc être pertinente dans un contexte où les liens entre les prix de marché de l'énergie et l'inflation observée ne sont pas nécessairement stables dans le temps.

La littérature sur la prévision de l'inflation montre toutefois que la performance des modèles dépend fortement de la nature de l'inflation étudiée. Les modèles de séries temporelles classiques permettent généralement de représenter l'inertie de l'inflation alors que les modèles intégrant des variables explicatives cherchent à améliorer la prévision en mobilisant des informations économiques supplémentaires. Dans le cas de l'inflation énergétique, cette question est particulièrement importante car les prix de l'énergie dépendent de marchés internationaux volatils, sensibles aux chocs géopolitiques, climatiques et d'approvisionnement. Les travaux consacrés aux prix du gaz naturel et aux marchés énergétiques soulignent ainsi que ces séries peuvent présenter des ruptures, des épisodes extrêmes et des relations instables avec les autres variables économiques (Chen, Hartley et Lan, 2023 ; Su et al., 2023 ; Shen et al., 2023).

Ce mémoire ne cherche donc pas à proposer un modèle structurel complet de l'inflation énergétique mais à comparer plusieurs outils de prévision appliqués à une période récente marquée par des chocs importants. Sa contribution principale est donc empirique, elle consiste à évaluer si une méthode non linéaire comme la Random Forest (notamment lorsqu'elle est réestimée en rolling window) permet d'améliorer la prévision par rapport à des modèles plus classiques et à une référence naïve.

La problématique retenue est donc la suivante : peut-on réellement prévoir l'inflation énergétique en France à partir des prix du pétrole, du gaz naturel et des matières premières, alors que cette inflation est fortement dépendante de chocs économiques et géopolitiques ?

Cette problématique comporte deux enjeux. Le premier est prédictif. Il s'agit d'évaluer si les variables retenues permettent d'améliorer la prévision de l'inflation énergétique par rapport à des modèles plus simples. Le second est économique. Il s'agit de déterminer dans quelle mesure les prix de marché, notamment le Brent et le gaz naturel, apportent une information utile pour comprendre l'évolution de l'inflation énergétique. L'objectif n'est donc pas seulement d'obtenir le meilleur indicateur statistique possible mais aussi de discuter les limites de la prévision dans un contexte marqué par des chocs externes, des ruptures de tendance et une forte volatilité.

Sur le plan méthodologique, ce mémoire mobilise plusieurs approches complémentaires. Un modèle ARMAX est d'abord utilisé comme modèle linéaire de référence car il permet d'intégrer à la fois une dynamique temporelle et des variables explicatives économiques. La méthode Random Forest est ensuite mobilisée comme modèle principal afin de tester l'intérêt d'une approche non linéaire pour prévoir l'inflation énergétique. Plusieurs spécifications de Random Forest sont comparées selon les variables explicatives intégrées. Dans un second temps, des

modèles de référence complémentaires sont ajoutés afin de renforcer l'évaluation empirique avec un modèle naïf, un modèle ARIMA univarié, une régression linéaire multiple ainsi qu'une version rolling window de la Random Forest. Ces modèles permettent de vérifier si les approches plus complexes apportent un gain réel par rapport à des règles de prévision plus simples.

L'apport de ce mémoire est donc double. D'une part, il propose une analyse empirique centrée sur l'inflation énergétique française à partir de données mensuelles récentes et incluant la période de crise énergétique. D'autre part, il compare plusieurs méthodes de prévision afin d'évaluer la robustesse des résultats. L'intégration d'un modèle naïf permet notamment de tester la capacité des modèles plus élaborés à dépasser une prévision très simple fondée sur la persistance de l'inflation. De même, l'approche rolling window permet d'étudier si une mise à jour progressive du modèle améliore la prévision dans un contexte instable. Enfin, les performances sont évaluées à l'aide de plusieurs indicateurs comme le RMSE, le MAE, le coefficient de détermination, la corrélation, le biais moyen, le sMAPE et le MASE, ainsi que par des tests de comparaison des erreurs de prévision.

Pour répondre à cette problématique, ce mémoire est organisé en trois parties. La première partie présente le contexte économique de l'inflation énergétique et justifie le choix des variables retenues. Elle revient sur la spécificité de l'inflation énergétique, sur le rôle du pétrole, du gaz naturel et des matières premières, et sur les mécanismes de transmission possibles vers les prix à la consommation. La deuxième partie expose la méthodologie de prévision. Elle présente la construction de la base de données, les transformations réalisées, le découpage entre période d'apprentissage et période de test ainsi que les différents modèles mobilisés. Et enfin, la troisième partie analyse les résultats empiriques. Elle compare les performances des modèles, étudie l'importance des variables, examine les erreurs de prévision et discute la capacité réelle des modèles à prévoir l'inflation énergétique dans un contexte marqué par des chocs économiques et géopolitiques.

Partie 1 : Inflation énergétique et marchés de l'énergie

1.1. Définition et intérêt économique de l'inflation énergétique

L'inflation énergétique désigne l'évolution des prix des biens et services liés à l'énergie. Elle concerne notamment les carburants, le gaz, l'électricité, le fioul domestique et plus largement les dépenses énergétiques supportées par les ménages et les entreprises. Dans ce mémoire, l'inflation énergétique est mesurée à partir de l'indice des prix à la consommation de l'énergie publié par l'INSEE. Cet indice permet de suivre l'évolution des prix de l'énergie payés par les ménages en France.

L'étude de cette variable présente un intérêt particulier car l'énergie occupe une place centrale dans l'économie. Pour les ménages comme dis précédemment, elle constitue une dépense contrainte à travers les dépenses de transport, de chauffage et d'électricité. Une hausse des prix de l'énergie affecte donc directement le pouvoir d'achat, en particulier lorsque les revenus ne progressent pas au même rythme. Pour les entreprises, l'énergie intervient dans les coûts de production, de transport et de distribution. Une hausse du prix du pétrole, du gaz ou de l'électricité peut ainsi se transmettre aux prix des biens et services vendus ce qui peut contribuer à alimenter l'inflation globale.

L'inflation énergétique se distingue également des autres composantes de l'inflation par sa forte volatilité. Les prix de l'énergie dépendent en grande partie de marchés internationaux, attachés aux variations rapides de l'offre et de la demande. Ils peuvent être influencés par les décisions des pays producteurs, les tensions géopolitiques, les conditions d'approvisionnement, les variations du taux de change ou encore les politiques publiques. Cette dépendance à des facteurs externes rend l'inflation énergétique plus instable et plus difficile à anticiper que d'autres composantes de l'indice des prix.

La période récente a renforcé l'intérêt de ce sujet. Après plusieurs années de variations relativement modérées, les prix de l'énergie ont fortement augmenté à partir de 2021, dans un contexte de reprise économique post-Covid, de tensions sur les marchés internationaux et de crise énergétique européenne. L'invasion de l'Ukraine par la Russie en 2022 a ensuite accentué les tensions, notamment sur le marché du gaz naturel. Cette succession de chocs a montré que l'inflation énergétique pouvait connaître des variations très rapides, difficiles à prévoir avec des modèles simples.

L'objectif de cette première partie est de présenter la variable cible du mémoire, d'expliquer sa méthode de calcul et de justifier le choix des variables explicatives retenues. L'analyse porte sur trois variables principales : le prix du pétrole Brent en euros, le prix du gaz naturel TTF et l'indice des matières premières importées hors énergie. Ces variables sont retenues car elles représentent différents canaux de transmission possibles vers l'inflation énergétique.

1.2. Mesure de l'inflation énergétique à partir de l'IPC énergie

La variable cible du mémoire est l'inflation énergétique en France. Elle est construite à partir de l'indice des prix à la consommation de l'énergie. Cet indice, exprimé en base 2015, mesure l'évolution des prix des biens énergétiques consommés par les ménages. Il permet donc de suivre le niveau général des prix de l'énergie dans la consommation des ménages français.

Dans ce mémoire, l'inflation énergétique est calculée en glissement annuel. Le choix du glissement annuel permet de comparer le niveau de l'indice à un mois donné avec son niveau observé douze mois auparavant. Cette méthode est couramment utilisée pour analyser l'inflation, car elle permet de neutraliser en partie les variations saisonnières et de mesurer une évolution annuelle des prix.

La formule utilisée est la suivante :

$$\pi_t = ((IPC_{\text{energie},t}/IPC_{\text{energie},t-12}) - 1) \times 100$$

où π_t représente l'inflation énergétique au mois t , $IPC_{\text{energie},t}$ désigne la valeur de l'indice des prix à la consommation de l'énergie au mois t , et $IPC_{\text{energie},t-12}$ correspond à la valeur de ce même indice 1 an avant.

Cette transformation permet d'obtenir une série exprimée en pourcentage. Une valeur positive signifie que les prix de l'énergie sont plus élevés qu'un an auparavant. À l'inverse une valeur négative indique que les prix de l'énergie sont inférieurs à leur niveau observé un an plus tôt. Ainsi les valeurs négatives observées à certaines périodes ne doivent pas être interprétées comme une erreur statistique mais plutôt comme une baisse effective des prix de l'énergie en glissement annuel. Ce choix de mesure s'appuie sur l'indice des prix à la consommation qui constitue l'un des principaux indicateurs utilisés pour suivre l'évolution des prix payés par les ménages (INSEE, 2025).

Le choix du glissement annuel présente toutefois une conséquence importante pour la prévision. Comme la variable dépend de sa valeur observée douze mois plus tôt, elle peut présenter une certaine inertie. Autrement dit, l'inflation énergétique d'un mois donné est souvent proche de celle du mois précédent, sauf en période de choc ou de retournement brutal. Cette caractéristique explique pourquoi un modèle naïf, fondé sur la valeur passée immédiate, peut parfois obtenir de bonnes performances. Cette question sera étudiée plus précisément plus loin dans la partie empirique du mémoire.

1.3. Évolution récente de l'inflation énergétique en France

L'analyse descriptive réalisée à partir de la base de données met en évidence une forte volatilité de l'inflation énergétique en France entre juillet 2015 et septembre 2025. Sur cette période,

l'indice des prix à la consommation de l'énergie évolue de manière relativement modérée jusqu'en 2020 avant de connaître une nette accélération à partir de 2021.

Les années 2015-2016 sont marquées par des valeurs négatives de l'inflation énergétique. Cela signifie que l'indice des prix de l'énergie est inférieur à son niveau observé un an auparavant. Cette période correspond notamment à une baisse importante des prix de l'énergie, dans un contexte de recul du prix du pétrole. Ces valeurs négatives traduisent donc une baisse effective des prix de l'énergie en glissement annuel.

La période 2021-2022 constitue au contraire un épisode de forte hausse. L'inflation énergétique atteint alors des niveaux particulièrement élevés avec un pic supérieur à 30 % dans la base étudiée. Cette évolution reflète les tensions importantes observées sur les marchés de l'énergie, en particulier sur le gaz naturel et le pétrole. Elle montre que l'inflation énergétique peut être fortement affectée par des chocs conjoncturels.


Après ce pic, l'inflation énergétique diminue progressivement. Cette désinflation ne signifie pas nécessairement que les prix de l'énergie reviennent à leur niveau initial mais plutôt que leur rythme de progression ralentit par rapport à l'année précédente. Cette différence est importante car une inflation plus faible peut coexister avec des prix encore élevés. L'analyse de l'indice en niveau et de son taux de variation permet donc de distinguer l'évolution du niveau des prix et l'évolution de leur rythme de croissance.



Source : INSEE, avec calculs.

Figure 1: Évolution de l'indice des prix à la consommation de l'énergie

La Figure 1 permet d'observer cette évolution en niveau. Cette rupture correspond à la période de tensions sur les marchés de l'énergie, marquée notamment par la reprise post-Covid et la crise énergétique européenne. L'indice atteint ses niveaux les plus élevés en 2022-2023 avant de se stabiliser partiellement sur la fin de la période.



Source : INSEE, avec calculs.

Figure 2: Inflation énergétique en France

La Figure 2 montre que l'inflation énergétique apparaît beaucoup plus volatile que l'indice en niveau. Elle met particulièrement en évidence le pic supérieur à 30 % observé en 2021-2022. Cette évolution confirme que l'inflation énergétique est particulièrement sensible aux chocs conjoncturels et aux fluctuations des prix internationaux de l'énergie.

Ces premiers éléments justifient la problématique du mémoire. Il ne s'agit pas seulement d'observer la hausse des prix de l'énergie mais de se demander dans quelle mesure cette inflation peut être anticipée à partir de variables économiques observables telles que le prix du pétrole Brent, le prix du gaz naturel TTF et les matières premières importées. Des évaluations descriptives complémentaires sont également présentées en annexe. Les statistiques descriptives détaillées présentées dans le Tableau 16 et la distribution des principales variables représentée dans la Figure 14 confirment la forte volatilité de l'inflation énergétique et des variables de marché, en particulier du gaz naturel TTF. La détection des points atypiques (présentée dans le Tableau 17) met aussi en évidence plusieurs ruptures de niveau correspondant aux principaux épisodes de choc observés sur la période. La Figure 15 permet de comparer la série observée et la série corrigée de ces points atypiques.

1.4. Justification économique des variables explicatives

Les variables explicatives retenues dans ce mémoire répondent à une logique économique. Elles ont été choisies afin de représenter les principaux facteurs susceptibles d'influencer l'inflation énergétique en France tout en restant cohérentes avec les données disponibles à fréquence mensuelle. Trois variables principales sont utilisées : le prix du pétrole Brent en euros, le prix du gaz naturel TTF et l'indice des matières premières importées hors énergie. Des variables retardées sont ensuite construites afin de tenir compte des délais de transmission entre les prix de marché et les prix à la consommation.

Le Brent est un prix de référence international du pétrole brut. Il constitue l'un des principaux indicateurs utilisés pour suivre l'évolution du marché pétrolier mondial. Ici le Brent est retenu en euros par baril afin de représenter le coût du pétrole pour les agents économiques français. Ce choix est important car une série exprimée en euros tient compte du prix du pétrole mais aussi des variations du taux de change euro-dollar.

Le prix du pétrole influence directement plusieurs composantes de l'énergie consommée par les ménages. C'est notamment le cas des carburants, du fioul domestique et de certains produits pétroliers. Lorsque le prix du Brent augmente, cette hausse peut se transmettre aux prix à la consommation même si cette transmission n'est pas toujours immédiate. Elle peut dépendre des taxes, des marges de distribution, des délais d'ajustement et du contexte économique. Le Brent peut également avoir un effet indirect sur l'inflation car une hausse du pétrole augmente les coûts de transport et de production des entreprises. La littérature sur les marchés énergétiques souligne que les prix du pétrole et du gaz présentent des dynamiques complexes (souvent marquées par de la volatilité, des effets de seuil et des relations non linéaires avec d'autres variables économiques) (Chen, Hartley et Lan, 2023 ; Su et al., 2023).




Figure 3: Évolution du prix du pétrole Brent

La Figure 3 montre que le prix du Brent connaît plusieurs phases distinctes sur la période étudiée. Il baisse fortement en 2015-2016 puis chute à nouveau en 2020 dans le contexte de la crise sanitaire. À partir de 2021, il augmente avec la reprise économique mondiale et les tensions sur les marchés énergétiques. Cette variable est donc pertinente pour expliquer l'inflation énergétique notamment à travers son effet sur les carburants, le fioul domestique et les produits pétroliers.

Le gaz naturel TTF est un prix de référence du gaz en Europe. Le TTF (Title Transfer Facility) correspond à un point d'échange virtuel situé aux Pays-Bas. Il est largement utilisé pour suivre les prix du gaz naturel sur le marché européen. Dans la base utilisée, cette variable est exprimée en euros par mégawattheure.

Le gaz TTF occupe une place centrale dans l'analyse de la crise énergétique récente. Jusqu'en 2020 son prix est resté relativement stable. À partir de 2021, il a augmenté fortement, avant d'atteindre un niveau exceptionnel en 2022. Cette hausse traduit les tensions d'approvisionnement sur le marché européen du gaz, dans le contexte de reprise économique, de tensions géopolitiques et de forte incertitude sur les approvisionnements.

Cette évolution est importante pour comprendre l'inflation énergétique en France. Même si la France dépend moins du gaz que certains autres pays européens pour sa production d'électricité, les prix du gaz influencent directement les factures des ménages et des entreprises. Ils peuvent également affecter les prix de l'électricité sur les marchés européens car le gaz joue un rôle dans la formation des prix de gros de l'électricité. Le gaz TTF est donc une variable particulièrement pertinente pour analyser la période 2021-2022. Son inclusion dans la base permet de capter un choc énergétique majeur qui ne serait pas entièrement représenté par le seul prix du pétrole Brent. Le prix du gaz naturel est particulièrement sensible aux conditions de stockage, aux variations de température et aux tensions d'approvisionnement, ce qui renforce son intérêt comme variable explicative dans l'analyse des prix de l'énergie (Chen, Hartley et Lan, 2023).




Figure 4: Évolution du prix du gaz naturel TTF

La Figure 4 montre que le prix du gaz naturel TTF reste relativement stable jusqu'en 2020 puis augmente très fortement à partir de 2021. Le pic observé en 2022 illustre le caractère exceptionnel de la crise énergétique européenne. Cette évolution rend le gaz TTF particulièrement important dans l'analyse car il capte un choc énergétique majeur qui ne serait pas entièrement représenté par le seul prix du pétrole Brent.

L'indice des matières premières importées hors énergie est utilisé comme variable de contexte. Contrairement au Brent et au gaz TTF, il ne mesure pas directement un prix énergétique. Il permet toutefois de tenir compte d'un environnement plus général de tensions sur les marchés internationaux des matières premières. Ces tensions peuvent être liées à la reprise économique mondiale, aux contraintes d'approvisionnement ou aux variations des coûts de production. Son lien avec l'inflation énergétique est donc moins direct que celui du Brent ou du gaz TTF mais il peut apporter une information complémentaire au modèle.




Figure 5: Évolution de l'indice des matières premières importées hors énergie

La Figure 5 montre que l'indice des matières premières importées hors énergie suit une tendance globalement à la hausse sur la période avec une progression marquée après 2020. Cette variable ne mesure pas directement les prix de l'énergie mais elle permet de tenir compte d'un contexte plus général de tensions sur les marchés internationaux des matières premières. Son rôle est donc complémentaire à celui du Brent et du gaz TTF.

Enfin, plusieurs variables retardées sont introduites dans la base. Les retards de l'inflation énergétique permettent de prendre en compte la dynamique propre de la variable cible. Les retards du Brent, du gaz TTF et des matières premières permettent de tenir compte d'éventuels délais de transmission entre les prix de marché et les prix à la consommation. Cette logique est

importante car les variations du pétrole ou du gaz ne se transmettent pas nécessairement et immédiatement à l'indice des prix à la consommation de l'énergie.

Les graphiques détaillés associés à ces variables sont présentés dans l'annexe consacrée à la Partie 1, afin de compléter la lecture des évolutions observées dans le corps du texte.

1.5. Des relations économiques instables en période de chocs

La prévision de l'inflation énergétique est particulièrement difficile car les prix de l'énergie sont soumis à de nombreux chocs. Ces chocs peuvent être économiques, géopolitiques, sanitaires ou réglementaires. La crise sanitaire de 2020 a par exemple provoqué une chute brutale de la demande mondiale d'énergie tandis que la crise énergétique de 2021-2022 a entraîné une hausse rapide des prix du gaz et du pétrole. Cette difficulté est cohérente avec les travaux consacrés aux marchés du gaz naturel qui montrent que les prix et la volatilité du gaz peuvent être influencés par des facteurs géopolitiques, climatiques et macroéconomiques difficiles à anticiper (Su et al., 2023 ; Shen et al., 2023).

Ces épisodes montrent que l'inflation énergétique ne suit pas toujours une trajectoire régulière. Elle peut connaître des ruptures importantes avec des phases de baisse rapide puis de forte hausse. Cette instabilité rend la prévision plus complexe que pour des séries économiques plus régulières. Elle peut également modifier les relations entre les variables explicatives et la variable cible (une relation observée sur une période stable peut ne plus être valable en période de crise).

C'est dans ce contexte que s'inscrit la problématique du mémoire : peut-on *réellement* prévoir l'inflation énergétique en France à partir des prix du pétrole, du gaz naturel et des matières premières, alors que cette inflation est fortement *dépendante* de chocs économiques et géopolitiques ?

Cette question met en évidence une tension importante. D'un côté, les prix du pétrole et du gaz constituent des déterminants économiques pertinents de l'inflation énergétique. De l'autre, les chocs récents montrent que les relations entre ces variables peuvent être instables, non linéaires et difficiles à modéliser avec des méthodes classiques. L'utilisation d'une approche Random Forest permet alors d'explorer cette question sous un angle prévisionnel car cette méthode peut capter des relations non linéaires entre les variables et identifier les prédictors les plus utiles pour prévoir l'inflation énergétique.

1.6. Synthèse de la première partie

Cette première partie a permis de présenter la variable cible du mémoire et de justifier le choix des variables explicatives retenues. L'inflation énergétique est mesurée en glissement annuel à partir de l'indice des prix à la consommation de l'énergie. Cette mesure permet d'analyser l'évolution annuelle des prix de l'énergie tout en conservant une fréquence mensuelle.

L'analyse descriptive met en évidence une forte volatilité de l'inflation énergétique sur la période juillet 2015 à septembre 2025. Les épisodes de baisse observés en 2015-2016 et la forte hausse de 2021-2022 montrent que cette variable est particulièrement sensible aux chocs économiques et géopolitiques. Le Brent, le gaz naturel TTF et les matières premières importées hors énergie apparaissent alors comme des variables pertinentes pour étudier cette dynamique même si leurs effets peuvent être différés et instables.

Le tableau suivant résume les principales variables mobilisées dans la base de données.

Tableau 2: Synthèse des variables utilisées dans l'analyse

Variable	Rôle	Justification économique	Source
Inflation énergétique	Variable cible	Mesure l'évolution annuelle des prix de l'énergie à partir de l'IPC énergie	INSEE
Brent en euros	Variable explicative	Capte les tensions sur le marché pétrolier et les effets sur les carburants et produits pétroliers	INSEE
Gaz naturel TTF	Variable explicative	Représente les tensions sur le marché européen du gaz, particulièrement importantes en 2021-2022	INSEE
Matières premières hors énergie	Variable explicative de contexte	Permet de tenir compte d'un environnement général de tensions sur les marchés internationaux	INSEE
Variables retardées	Variables dynamiques	Captent l'inertie de l'inflation énergétique et les délais de transmission des prix de marché	Calculs

Une présentation complémentaire des variables mobilisées incluant leurs unités et leur rôle dans l'analyse est proposée en Tableau 15.

Cette synthèse montre que la base construite est cohérente avec l'objectif du mémoire qui est d'analyser et de prévoir l'inflation énergétique en France à partir de variables liées aux marchés de l'énergie et aux matières premières. La partie suivante présente la méthodologie retenue pour exploiter ces données, en comparant une approche économétrique de référence, fondée sur le modèle ARMAX, et une approche d'apprentissage automatique, fondée sur la méthode Random Forest.

Partie 2 : Méthodologie de prévision

2.1. Objectif de la modélisation

L'objectif de cette partie est de présenter la méthodologie retenue pour prévoir l'inflation énergétique en France. Après avoir défini la variable cible et justifié économiquement les variables explicatives dans la première partie, on va maintenant devoir évaluer leur capacité prédictive.

La variable que l'on cherche à prévoir est l'inflation énergétique, calculée en glissement annuel à partir de l'indice des prix à la consommation de l'énergie. Cette variable présente une forte volatilité sur la période étudiée surtout lors de la crise énergétique de 2021-2022. Cette instabilité rend la prévision plus complexe car les relations entre les prix de marché et les prix à la consommation peuvent varier selon les périodes.

Pour répondre à la problématique, plusieurs approches sont mobilisées. Une première famille de modèles repose sur des méthodes classiques de séries temporelles et de régression. Elle comprend un modèle naïf, un modèle ARIMA univarié, une régression linéaire multiple et un modèle ARMAX. Ces modèles servent de points de comparaison pour évaluer les performances des méthodes plus flexibles.

Une seconde approche repose sur la Random. Cette méthode constitue le modèle principal du mémoire car elle permet de prendre en compte des relations potentiellement non linéaires entre les variables explicatives et l'inflation énergétique. Plusieurs spécifications de Random Forest sont comparées afin d'identifier les variables les plus utiles à la prévision.

Enfin, des extensions complémentaires sont introduites afin de renforcer l'analyse (une Random Forest pondérée, une Random Forest en rolling window et une analyse de robustesse sur plusieurs graines aléatoires). L'objectif n'est donc pas seulement de produire une prévision mais aussi d'évaluer la stabilité des résultats et les limites des modèles dans un contexte marqué par des chocs importants.¹

2.2. Construction de la base et de la variable cible

La base de données utilisée dans ce mémoire est mensuelle et couvre la période allant de juillet 2015 à septembre 2025.² Elle contient 123 observations après construction des variables retardées. Le choix d'une fréquence mensuelle permet de suivre de manière relativement plus précise les variations de l'inflation énergétique tout en conservant une taille d'échantillon exploitable pour les modèles de prévision.

¹L'ensemble des estimations et traitements statistiques est réalisé avec le logiciel R, via RStudio. Les principaux packages utilisés sont `dplyr`, `ggplot2`, `forecast`, `randomForest`, `yardstick`, `tseries`, `tsoutliers`, `knitr` et `kableExtra`.

²Les données des modèles viennent surtout de l'INSEE. La Banque de France est utilisée pour expliquer le contexte économique récent, notamment la hausse de l'inflation et les mesures liées aux prix de l'énergie.

La variable cible est l'inflation énergétique en France. Elle est construite à partir de l'indice des prix à la consommation de l'énergie publié par l'INSEE. Cet indice permet de mesurer l'évolution des prix des biens énergétiques consommés par les ménages.

Dans ce mémoire, l'inflation énergétique est calculée en glissement annuel. La formule utilisée est la suivante :

$$\pi_t = \left(\frac{IPC_{\text{energie},t}}{IPC_{\text{energie},t-12}} - 1 \right) \times 100$$

où π_t représente l'inflation énergétique au mois t , $IPC_{\text{energie},t}$ désigne la valeur de l'indice des prix à la consommation de l'énergie au mois t , et $IPC_{\text{energie},t-12}$ correspond à la valeur de ce même indice douze mois auparavant.

Cette transformation permet d'obtenir un taux de variation annuel exprimé en pourcentage. Elle est adaptée à l'analyse de l'inflation car elle compare chaque mois avec le même mois de l'année précédente. Les valeurs positives traduisent une hausse des prix de l'énergie en glissement annuel alors que les valeurs négatives indiquent que les prix de l'énergie sont inférieurs à leur niveau observé un an auparavant.

2.3. Variables explicatives et variables retardées

Les variables explicatives retenues sont choisies à partir de la logique économique présentée dans la première partie. Elles correspondent aux principaux facteurs susceptibles d'influencer l'inflation énergétique en France.

Le prix du pétrole Brent en euros permet de capter les tensions sur le marché pétrolier mondial en tenant compte du coût effectif du pétrole pour les agents économiques français. Le prix du gaz naturel TTF représente les tensions sur le marché européen du gaz. L'indice des matières premières importées hors énergie est ajouté comme variable de contexte pour tenir compte d'un environnement plus général de tensions sur les marchés internationaux.

En plus de ces variables, plusieurs variables retardées sont introduites. Les retards permettent de prendre en compte la dimension temporelle de la série et les délais possibles de transmission entre les prix de marché et les prix à la consommation. En effet une hausse du prix du pétrole ou du gaz ne se répercute pas forcément tout de suite sur l'indice des prix de l'énergie. De même, l'inflation énergétique présente une certaine inertie, ce qui justifie l'utilisation de ses propres valeurs passées.

Les retards de l'inflation énergétique à 1, 3, 6 et 12 mois sont retenus afin de représenter la dynamique propre de la variable cible. Les retards du Brent et du gaz naturel TTF à 1 et 3 mois permettent de capter une transmission de court terme vers les prix de l'énergie. Les matières premières hors énergie sont également intégrées avec des retards de 1 et 3 mois car leur rôle est davantage interprété comme une variable de contexte.

La pertinence de ces variables retardées est également vérifiée par des diagnostics complémentaires présentés en annexe. La décomposition STL de l'inflation énergétique, présentée dans la Figure 17, met en évidence une tendance marquée jusqu'en 2022 puis une baisse progressive. Les fonctions d'autocorrélation simple et partielle, présentées dans les Figure 18 et Figure 19, soulignent quant à elles une forte inertie de la série. Ces éléments justifient l'introduction de retards de l'inflation énergétique dans les modèles de prévision.

La sélection des variables tient aussi compte de la taille de l'échantillon. Comme la base finale contient 123 observations mensuelles, il est nécessaire de conserver un nombre raisonnable de prédicteurs. Ajouter un trop grand nombre de retards pourrait complexifier inutilement les modèles et augmenter le risque de surapprentissage (en particulier pour les méthodes d'apprentissage automatique).

Le tableau suivant présente les principales variables utilisées dans la modélisation.

Tableau 3: Variables utilisées dans les modèles de prévision

Variable	Rôle	Retards utilisés
Inflation énergétique	Variable cible et variable dynamique	1, 3, 6 et 12 mois
Brent en euros	Variable explicative énergétique	1 et 3 mois
Gaz naturel TTF	Variable explicative énergétique	1 et 3 mois
Matières premières hors énergie	Variable explicative de contexte	1 et 3 mois

Des tests exploratoires de sélection de variables ont enfin été réalisés à l'aide des méthodes Best Subset et GETS. Les résultats sont présentés dans le Tableau 20 et le Tableau 21. Ces tests ne remplacent pas la stratégie principale du mémoire, fondée sur la comparaison des performances de prévision hors échantillon, mais ils permettent de vérifier si certaines variables ressortent également dans un cadre linéaire.

2.4. Découpage apprentissage-test

Afin d'évaluer la capacité prédictive des modèles, la base est séparée en deux échantillons : un échantillon d'apprentissage et un échantillon de test. L'échantillon d'apprentissage sert à estimer les modèles et l'échantillon de test permet de comparer les prévisions produites aux valeurs réellement observées.

Le découpage retenu est chronologique pour respecter la structure temporelle des données. Les observations les plus anciennes sont utilisées pour l'apprentissage et les observations les plus récentes sont réservées au test. Cette démarche évite d'utiliser des informations futures pour prévoir le passé.

Le découpage principal est le suivant :

Tableau 4: Découpage chronologique de la base de données

Échantillon	Période	Rôle
Apprentissage	Juillet 2015 à décembre 2021	Estimation des modèles
Test	Janvier 2022 à septembre 2025	Évaluation des prévisions

Ce choix permet de tester les modèles sur une période particulièrement exigeante marquée par la crise énergétique de 2021-2022 puis par une phase de désinflation. La période de test contient donc des variations rapides de l'inflation énergétique ce qui permet d'évaluer la capacité réelle des modèles à prévoir dans un contexte instable.

2.5. Modèles de référence : modèle naïf, ARIMA et régression linéaire

Avant d'évaluer les modèles plus complexes, plusieurs modèles de référence sont estimés. Leur rôle est de fournir des points de comparaison simples. Cette étape est importante car un modèle complexe n'est réellement pertinent que s'il améliore les performances par rapport à des modèles plus simples.

Le premier modèle de référence est le modèle naïf. Il consiste à prévoir l'inflation énergétique du mois courant par la valeur observée au mois précédent :

$$\hat{y}_t = y_{t-1}$$

où $\hat{y}_t$ représente la prévision de l'inflation énergétique au mois t et y_{t-1} la valeur observée le mois précédent. Ce modèle est très simple, mais il constitue une référence importante lorsque la série présente une forte inertie. Dans le cas de l'inflation énergétique en glissement annuel, il est possible que la valeur du mois précédent soit déjà très informative.

Un modèle ARIMA univarié est aussi estimé. Contrairement aux modèles avec variables explicatives, il repose uniquement sur la dynamique passée de l'inflation énergétique. De manière générale, un modèle ARIMA peut être représenté comme une combinaison de termes autorégressifs, de différenciation et de moyenne mobile :

$$ARIMA(p, d, q)$$

où p représente l'ordre autorégressif, d l'ordre de différenciation et q l'ordre de moyenne mobile. Dans ce mémoire, le modèle ARIMA est sélectionné automatiquement à partir de la série d'apprentissage, puis ses prévisions seront comparées aux autres modèles. Les modèles

ARIMA constituent une famille classique de modèles de séries temporelles, couramment utilisée pour représenter la dynamique passée d'une variable et produire des prévisions à court terme (Hyndman et Athanasopoulos, 2021).

Une régression linéaire multiple est enfin utilisée comme référence supplémentaire. Elle permet d'évaluer la relation linéaire entre l'inflation énergétique et les variables retardées retenues dans la base. Sa forme générale peut être écrite comme ceci :

$$y_t = \alpha + \sum_{j=1}^k \beta_j X_{j,t} + \varepsilon_t$$

où $X_{j,t}$ représente les variables explicatives et retardées, β_j les coefficients associés, et ε_t le terme d'erreur. Ce modèle présente l'avantage d'être bien interprétable mais il repose sur une hypothèse de relation linéaire entre les variables.

Ces modèles de référence permettent donc d'évaluer si les approches plus élaborées, notamment l'ARMAX et la Random Forest, apportent un gain prédictif réel.³

2.6. Modèle linéaire dynamique : ARX et extension ARMAX

Le modèle ARX constitue le point de départ de l'analyse linéaire. Un modèle ARX est un modèle autorégressif avec variables explicatives exogènes. Il combine donc deux sources d'information : les valeurs passées de la variable à prévoir et les variables économiques extérieures.

Dans ce mémoire, le modèle ARX permet d'expliquer l'inflation énergétique à partir de ses propres retards mais aussi à partir des prix du Brent, du gaz naturel TTF et des matières premières. Il peut être présenté de manière simplifiée sous la forme suivante :

$$y_t = \alpha + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=1}^k \beta_j X_{j,t} + \varepsilon_t$$

où y_t représente l'inflation énergétique au mois t , y_{t-i} ses valeurs retardées, $X_{j,t}$ les variables explicatives liées aux marchés de l'énergie et aux matières premières, et ε_t le terme d'erreur.

Ce modèle est utilisé comme point de départ car il est simple, interprétable et cohérent avec les méthodes classiques de prévision avec variables explicatives. Il permet d'évaluer si les variables retenues apportent une information utile pour prévoir l'inflation énergétique. Toutefois, il repose sur une hypothèse de linéarité et suppose que les erreurs ne présentent pas de structure temporelle résiduelle importante. Les modèles avec variables explicatives permettent d'intégrer

³Plusieurs essais économétriques ont été réalisés avant de stabiliser la méthodologie finale, notamment des modèles ARX, ARMAX, ARIMA, une régression linéaire multiple, plusieurs spécifications de Random Forest, une Random Forest pondérée et une Random Forest en fenêtre mobile. Les variantes non retenues dans le corps du texte sont présentées ou mentionnées en annexe.

des informations économiques externes dans la dynamique de prévision, tout en conservant un cadre interprétable issu de l'économétrie des séries temporelles (Hamilton, 1994 ; Stock et Watson, 2019).

Pour vérifier cette hypothèse, les résidus du modèle ARX sont analysés à l'aide du test de Ljung-Box. Ce test permet d'évaluer l'hypothèse nulle d'absence d'autocorrélation des résidus. Lorsque la p-value est inférieure à 5 %, l'hypothèse d'absence d'autocorrélation est rejetée, ce qui indique que le modèle n'a pas capté toute la dynamique temporelle de la série.

Les résultats des tests de Ljung-Box montrent que les résidus du modèle ARX présentent encore une autocorrélation significative, notamment aux retards 12 et 18. Une extension ARMAX est donc estimée afin de tenir compte de cette autocorrélation résiduelle. Le modèle ARMAX conserve les variables explicatives du modèle ARX, mais ajoute une structure ARMA dans les erreurs.

La forme générale du modèle ARMAX peut être écrite de la manière suivante :

$$y_t = \alpha + \sum_{j=1}^k \beta_j X_{j,t} + u_t$$

avec :

$$u_t = \sum_{i=1}^p \phi_i u_{t-i} + \sum_{l=1}^q \theta_l \varepsilon_{t-l} + \varepsilon_t$$

où u_t représente l'erreur structurée du modèle, ϕ_i les coefficients autorégressifs des erreurs, θ_l les coefficients de moyenne mobile et ε_t un bruit blanc.

Dans ce mémoire, le modèle ARMAX sélectionné correspond à une régression avec variables explicatives et erreurs ARIMA(1,0,0). Les tests appliqués aux résidus de ce modèle ne rejettent plus l'hypothèse d'absence d'autocorrélation, ce qui justifie son utilisation comme modèle linéaire de référence. Les résultats détaillés des tests de Ljung-Box sont présentés en annexe.

Tableau 5: Tests de Ljung-Box sur les résidus des modèles ARX et ARMAX

Modele	Retard	p-value
ARX	6	0.050
ARX	12	0.046
ARX	18	0.023
ARMAX	6	0.975
ARMAX	12	0.861
ARMAX	18	0.961

2.7. Modèle principal : Random Forest

La Random Forest est une méthode d'apprentissage supervisé fondée sur l'agrégation de plusieurs arbres de décision. Dans le cadre d'un problème de régression, chaque arbre produit une prévision numérique, puis la prévision finale est obtenue en faisant la moyenne des prévisions de l'ensemble des arbres. Cette méthode est particulièrement utile lorsque les relations entre les variables sont non linéaires ou lorsque des interactions complexes peuvent exister entre les prédictors (James et al., 2021).

Un arbre de décision fonctionne en divisant progressivement l'échantillon en sous-groupes à partir des variables explicatives. À chaque étape, l'algorithme choisit la variable et le seuil qui permettent de réduire au mieux l'erreur de prévision. Par exemple, un arbre peut distinguer les périodes où le prix du gaz est très élevé de celles où il reste plus modéré.

Un seul arbre peut être instable car il dépend fortement des données utilisées. La Random Forest réduit cette instabilité en construisant un grand nombre d'arbres sur des sous-échantillons différents. De plus, à chaque séparation, seule une partie des variables explicatives est considérée. Cette double source d'aléa permet de limiter le risque de surapprentissage et d'améliorer la capacité de généralisation du modèle.

La prévision d'une Random Forest peut être résumée de la manière suivante :

$$\hat{f}_{RF}(x) = \frac{1}{B} \sum b = 1^B T_b(x)$$

où B représente le nombre d'arbres, $T_b(x)$ la prévision produite par l'arbre b , et $\hat{f}_{RF}(x)$ la prévision moyenne de la forêt.

Cette méthode présente plusieurs avantages pour le sujet étudié. D'abord, elle ne suppose pas de relation linéaire entre les variables explicatives et l'inflation énergétique. Ensuite, elle peut prendre en compte des interactions entre variables (par exemple entre le prix du gaz, le prix du pétrole et les retards de l'inflation). Enfin, elle permet d'obtenir une mesure de l'importance des variables, ce qui aide à identifier les prédictors les plus utiles.

Dans ce mémoire, plusieurs spécifications de Random Forest sont estimées. Elles diffèrent par les variables intégrées dans le modèle. Cette démarche permet d'évaluer si l'ajout de variables explicatives améliore la prévision par rapport à un modèle fondé uniquement sur les retards de l'inflation énergétique.

Tableau 6: Spécifications des modèles Random Forest

Modèle	Variables utilisées
RF1	Retards de l'inflation énergétique
RF2	Retards de l'inflation énergétique et retards du Brent
RF3	Retards de l'inflation énergétique, retards du Brent et retards du gaz TTF
RF4	Retards de l'inflation énergétique, retards du Brent, retards du gaz TTF et retards des matières premières hors énergie

La Random Forest constitue donc le modèle principal de l'analyse. Elle est particulièrement adaptée au sujet car l'inflation énergétique est influencée par des chocs économiques et géopolitiques susceptibles de modifier les relations entre les variables. Toutefois, cette méthode présente aussi certaines limites. Elle est moins directement interprétable qu'un modèle linéaire et peut être sensible à la taille de l'échantillon. Ces limites justifient l'utilisation de modèles de référence et de tests de robustesse.

2.8. Extensions méthodologiques : pondération, rolling window et robustesse

Afin de compléter l'analyse principale, plusieurs extensions méthodologiques sont réalisées.

La première extension est une Random Forest pondérée. L'objectif est de donner davantage d'importance aux observations les plus récentes dans l'apprentissage du modèle. Cette démarche peut être pertinente dans un contexte où les relations économiques évoluent au cours du temps. Les observations récentes peuvent en effet être plus représentatives du régime économique observé pendant la période de test.

La deuxième extension est une Random Forest estimée en rolling window. Dans cette approche, le modèle est réestimé progressivement à partir d'une fenêtre mobile d'observations passées. Pour chaque date de la période de test, le modèle est entraîné uniquement sur les observations précédant cette date, puis produit une prévision. Cette méthode respecte la logique temporelle de la prévision et permet au modèle de s'adapter plus rapidement aux changements récents. Dans un contexte de séries temporelles instables, la réestimation progressive des modèles permet de mieux tenir compte des changements de régime et de l'évolution des relations entre les variables (Hyndman et Athanasopoulos, 2021).

Dans ce mémoire, la fenêtre mobile retenue contient 60 observations mensuelles. Ce choix permet de conserver un volume d'apprentissage suffisant tout en donnant un poids important aux observations récentes. La Random Forest rolling window est particulièrement intéressante dans le cas de l'inflation énergétique car la période de test comprend des changements de régime importants.

Enfin, une analyse de robustesse est réalisée sur plusieurs graines aléatoires. La Random Forest reposant sur des tirages aléatoires, ses résultats peuvent légèrement varier selon la graine utilisée. L'estimation du modèle sur 100 graines différentes permet donc d'évaluer la stabilité

des performances. Si les indicateurs de performance restent proches d'une graine à l'autre, cela renforce la fiabilité des résultats obtenus.

Ces extensions ne remplacent pas l'analyse principale mais permettent de discuter plus finement les résultats. Elles répondent à une question centrale du mémoire : les performances de la Random Forest sont-elles stables et réellement supérieures à celles des modèles de référence ?

2.9. Indicateurs de performance et tests de comparaison

Pour comparer les performances des modèles, plusieurs indicateurs d'erreur sont utilisés. Ces indicateurs permettent de mesurer les écarts entre les valeurs observées et les valeurs prévues sur la période de test.

Le premier indicateur est la racine de l'erreur quadratique moyenne, ou RMSE. Il mesure l'écart moyen entre les valeurs observées et les valeurs prévues, en donnant davantage de poids aux erreurs importantes :

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

Le deuxième indicateur est l'erreur absolue moyenne, ou MAE. Il mesure l'écart moyen en valeur absolue entre les valeurs observées et les valeurs prévues :

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

Le coefficient de détermination prédictif permet d'évaluer la capacité du modèle à reproduire les variations observées sur la période de test :

$$R^2 = 1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2}$$

La corrélation entre les valeurs observées et prévues est également utilisée afin d'évaluer si le modèle reproduit correctement la dynamique de la série, même lorsque le niveau exact de la prévision est imparfait.

Le biais moyen permet de savoir si un modèle a tendance à surestimer ou sous-estimer l'inflation énergétique :

$$Biais = \frac{1}{n} \sum_{t=1}^n (\hat{y}_t - y_t)$$

Enfin, deux indicateurs complémentaires sont utilisés : le sMAPE et le MASE. Le sMAPE mesure l'erreur relative symétrique, tandis que le MASE compare l'erreur du modèle à celle d'un modèle naïf. Ces indicateurs permettent de compléter la lecture du RMSE et du MAE, notamment lorsque les valeurs de la série sont très variables. Ces indicateurs sont couramment mobilisés pour comparer les performances prédictives car ils mesurent les erreurs de prévision selon des critères complémentaires (erreur quadratique, erreur absolue, erreur relative ou erreur mise à l'échelle) (Hyndman et Athanasopoulos, 2021).

En complément des indicateurs de performance, des tests de Diebold-Mariano sont réalisés. Ce test permet de comparer statistiquement les erreurs de prévision de deux modèles. L'hypothèse nulle correspond à une égalité de performance prédictive entre les deux modèles. Lorsque la p-value est inférieure à 5 %, l'hypothèse nulle est rejetée, ce qui signifie que les performances des deux modèles sont significativement différentes. Le test de Diebold-Mariano permet ainsi de déterminer si l'écart de performance entre deux modèles est statistiquement significatif, au-delà d'une simple différence d'indicateurs d'erreur (Diebold et Mariano, 1995).

Le test de Diebold-Mariano est particulièrement utile dans ce mémoire parce-que de faibles différences de RMSE ou de MAE ne suffisent pas toujours à conclure qu'un modèle est réellement meilleur. Il permet donc de distinguer les écarts statistiquement significatifs des différences plus fragiles.

2.10. Synthèse de la démarche méthodologique

La méthodologie retenue repose sur une comparaison progressive entre plusieurs familles de modèles. Le modèle naïf constitue une référence minimale, fondée sur la persistance de l'inflation énergétique. Le modèle ARIMA permet d'évaluer la capacité de la dynamique univariée à prévoir la série. La régression linéaire multiple et le modèle ARMAX introduisent ensuite des variables économiques explicatives.

Le modèle ARMAX est retenu comme modèle linéaire de référence car il permet de corriger l'autocorrélation résiduelle observée dans le modèle ARX. Il conserve une structure interprétable tout en tenant compte de la dynamique temporelle de la série.

La Random Forest constitue le modèle principal. Elle utilise les variables retardées retenues dans la base mais permet de relâcher l'hypothèse de linéarité. Elle est alors mobilisée afin de tester si une méthode plus flexible améliore les prévisions dans un contexte marqué par des chocs économiques et géopolitiques.

Pour finir, les extensions méthodologiques comme la Random Forest pondérée, la Random Forest rolling window et la robustesse sur plusieurs graines aléatoires, permettent de vérifier la stabilité des résultats. La démarche méthodologique complète est résumée par l'organigramme présenté en annexe (Figure 16).

Tableau 7: Synthèse de la démarche méthodologique

Étape	Choix_retenu	Objectif
Variable cible	Inflation énergétique en glissement annuel	Mesurer l'évolution annuelle des prix de l'énergie
Variables explicatives	Brent en euros, gaz naturel TTF, matières premières hors énergie	Tester l'apport des prix de marché à la prévision
Variables dynamiques	Retards de l'inflation, du Brent, du gaz et des matières premières	Prendre en compte l'inertie de la série et les délais de transmission
Découpage temporel	Apprentissage : juillet 2015 à décembre 2021 ; test : janvier 2022 à septembre 2025	Évaluer les modèles sur une période récente et instable
Modèles de référence	Modèle naïf, ARIMA et régression linéaire	Disposer de points de comparaison simples
Modèle linéaire dynamique	ARMAX	Intégrer des variables explicatives tout en corrigeant l'autocorrélation des erreurs
Modèle principal	Random Forest	Tester une méthode non linéaire et flexible
Extensions	Random Forest pondérée, rolling window et robustesse sur plusieurs graines	Vérifier l'adaptation temporelle et la stabilité des résultats
Évaluation	RMSE, MAE, R^2 , corrélation, biais, sMAPE, MASE et test de Diebold-Mariano	Comparer les performances prédictives et leur significativité

La partie suivante présente les résultats empiriques, compare les performances des modèles et discute la capacité réelle de ces approches à prévoir l'inflation énergétique en France.

Partie 3 : Résultats empiriques et interprétation

Cette troisième partie présente les résultats empiriques obtenus à partir des différents modèles de prévision estimés. L’objectif est d’évaluer la capacité des modèles à prévoir l’inflation énergétique en France sur la période de test allant de janvier 2022 à septembre 2025. Cette période est particulièrement exigeante car elle comprend le choc énergétique de 2022, le pic d’inflation énergétique puis la phase de désinflation observée ensuite.

L’analyse ne se limite pas à comparer un modèle Random Forest avec un modèle ARMAX. Elle repose désormais sur une comparaison plus large entre plusieurs familles de modèles : un modèle naïf, un modèle ARIMA univarié, une régression linéaire multiple, un modèle ARMAX, plusieurs Random Forest, une Random Forest pondérée et une Random Forest estimée en rolling window. Cette démarche permet de vérifier si les modèles complexes améliorent réellement la prévision par rapport à des approches plus simples.

Les performances sont évaluées à l’aide de plusieurs indicateurs : le RMSE, le MAE, le coefficient de détermination prédictif, la corrélation, le biais moyen, le SMAPE et le MASE. Des tests de Diebold-Mariano sont également mobilisés pour déterminer si les écarts de performance entre les modèles sont statistiquement significatifs.

3.1. Présentation de la base finale et analyse exploratoire

La base finale utilisée dans l’analyse couvre la période allant de juillet 2015 à septembre 2025. Elle contient 123 observations mensuelles après la construction de la variable cible et des variables retardées. Le début de la base en juillet 2015 s’explique par deux transformations principales : le calcul de l’inflation énergétique en glissement annuel, qui nécessite douze mois d’historique, puis la création de plusieurs retards des variables explicatives.

La période étudiée présente plusieurs caractéristiques importantes. Jusqu’en 2020, l’inflation énergétique évolue de manière relativement modérée avec des épisodes de baisse. À partir de 2021, elle augmente fortement dans un contexte de reprise économique post-Covid et de tensions sur les marchés de l’énergie. L’année 2022 constitue un épisode de choc majeur marqué par une forte hausse des prix du gaz et du pétrole puis par une phase de désinflation progressive. Cette évolution justifie l’utilisation d’un découpage chronologique apprentissage-test pour évaluer les modèles sur une période récente et instable.

L’analyse exploratoire de la base finale confirme ces caractéristiques. Les statistiques descriptives présentées en annexe (Tableau 16) montrent que l’inflation énergétique présente une moyenne positive, mais surtout une forte dispersion, avec un minimum de -11,01 % et un maximum de 33,05 %. Le gaz naturel TTF apparaît comme la variable la plus volatile, avec une distribution très asymétrique et une forte kurtosis, ce qui montre la présence d’épisodes extrêmes sur le marché européen du gaz. La détection des points atypiques (Tableau 17) met également en évidence plusieurs ruptures de niveau, notamment en 2021-2022 lors de la crise énergétique,

puis en 2023 pendant la phase de désinflation. Ces éléments confirment que la période de test constitue un cadre exigeant pour les modèles de prévision.

Les tests de stationnarité (Tableau 19) conduisent à une interprétation prudente. Le test ADF ne rejette pas l'hypothèse de racine unitaire et le test KPSS ne rejette pas l'hypothèse de stationnarité. Cette ambiguïté peut s'expliquer par la présence de chocs et de ruptures de niveau dans la série. Les graphiques d'autocorrélation confirment par ailleurs la forte dépendance temporelle de l'inflation énergétique ce qui justifie l'introduction de retards de la variable cible dans les modèles.

Ces diagnostics permettent de relier l'analyse exploratoire aux choix de modélisation. La forte inertie observée dans la série justifie l'utilisation du modèle naïf, des modèles autorégressifs et des retards de l'inflation énergétique dans les Random Forest. La volatilité importante, les ruptures de niveau et les valeurs extrêmes justifient elles la comparaison avec des méthodes plus flexibles, comme la Random Forest et l'utilisation d'une estimation en rolling window. Enfin, l'instabilité des variables de marché, en particulier du gaz TTF, montre que l'ajout de variables explicatives doit être évalué empiriquement plutôt que supposé bénéfique a priori.

3.2. Comparaison globale des modèles de prévision

Le tableau suivant présente les performances des principaux modèles estimés sur la période de test allant de janvier 2022 à septembre 2025.

Tableau 8: Comparaison globale des performances des modèles sur la période de test

Modèle	RMSE	MAE	R ²	Corrélation	Biais	sMAPE	MASE
Naïf	4.05	3.10	0.87	0.94	0.51	56.2	0.99
RF2 rolling window	4.95	4.06	0.81	0.91	1.61	69.3	1.29
RF2	6.58	5.18	0.67	0.89	0.11	81.9	1.65
RF2 pondéré	6.64	5.23	0.66	0.88	0.06	80.2	1.67
ARMAX	7.01	5.53	0.62	0.83	-2.77	96.1	1.76
Régression linéaire	7.62	5.38	0.55	0.79	-2.31	74.4	1.72
RF1	7.64	5.38	0.55	0.87	-3.01	75.0	1.72
RF3	7.70	6.60	0.54	0.88	2.44	98.5	2.10
RF4	7.86	6.80	0.52	0.89	3.46	99.1	2.17
ARIMA	9.79	7.72	0.26	0.81	-4.63	145.0	2.46
ARIMA corrigé	9.79	7.72	0.26	0.81	-4.63	145.0	2.46

Le Tableau 8 met en évidence un résultat important : le modèle naïf obtient les meilleures performances globales sur la période de test. Il présente le RMSE le plus faible, égal à 4,05,

le MAE le plus faible, égal à 3,10, ainsi que le R^2 prédictif le plus élevé, égal à 0,87. Ce résultat montre que l'inflation énergétique présente une forte inertie (la valeur observée le mois précédent constitue une information très utile pour prévoir la valeur du mois suivant). Ce résultat rappelle qu'un modèle complexe doit toujours être comparé à des références simples car une amélioration apparente n'est réellement informative que si elle dépasse une règle de prévision minimale (Hyndman et Athanasopoulos, 2021).

Le deuxième meilleur modèle est la Random Forest rolling window. Son RMSE est égal à 4,95 et son MAE à 4,06. Elle obtient également un R^2 élevé, égal à 0,81. Ce modèle ne dépasse donc pas le modèle naïf, mais il améliore nettement la Random Forest classique. Il constitue ainsi le meilleur modèle complexe parmi ceux estimés.

Le modèle RF2 classique, fondé sur les retards de l'inflation énergétique et les retards du Brent, arrive ensuite. Il obtient un RMSE de 6,58, un MAE de 5,18 et un R^2 de 0,67. Ces performances sont meilleures que celles du modèle ARMAX, du modèle ARIMA et de plusieurs autres Random Forest, mais elles restent inférieures à celles du modèle naïf et du RF2 rolling window.

Les modèles ARIMA et ARIMA corrigé obtiennent les performances les plus faibles. L'ARIMA corrigé donne les mêmes résultats que l'ARIMA simple car aucune correction d'outlier n'a été retenue sur la période d'apprentissage. Ce résultat indique que la dynamique univariée captée par ARIMA ne suffit pas à prévoir correctement l'inflation énergétique sur une période marquée par des chocs importants.

3.3. Interprétation du modèle naïf

Le fait que le modèle naïf obtienne les meilleures performances peut sembler surprenant car il s'agit du modèle le plus simple. Il consiste uniquement à prévoir l'inflation énergétique du mois courant par la valeur observée le mois précédent. Pourtant, dans ce cas, cette simplicité constitue un avantage.

L'inflation énergétique est calculée en glissement annuel. Cette construction crée une certaine inertie dans la série car deux mois consécutifs comparent chacun l'indice des prix de l'énergie à son niveau observé un an auparavant. En période de tendance prolongée, la valeur du mois précédent peut donc être très informative. Cela explique pourquoi le modèle naïf obtient un RMSE et un MAE plus faibles que les modèles plus complexes.

Cette interprétation est cohérente avec les diagnostics complémentaires présentés en annexe. L'ACF met en évidence une forte dépendance temporelle de l'inflation énergétique, alors que la sélection Best Subset retient principalement les retards de la variable cible. La bonne performance du modèle naïf s'explique donc en partie par l'inertie importante de l'inflation énergétique calculée en glissement annuel.

Ce résultat ne signifie pas que les variables économiques comme le Brent ou le gaz naturel sont inutiles. Il indique plutôt que sur la période de test, la persistance de l'inflation énergétique est

particulièrement forte. Les modèles plus complexes doivent donc être évalués avec prudence car leur intérêt ne se mesure pas uniquement à leur complexité mais aussi à leur capacité à améliorer une référence simple et robuste.

Le modèle naïf joue donc un rôle essentiel dans l'analyse. Il montre que la prévision de l'inflation énergétique doit être comparée à une référence minimale exigeante. Un modèle plus complexe n'est réellement pertinent que s'il parvient à dépasser cette référence ou à apporter une meilleure interprétation économique. Cette comparaison avec un modèle naïf permet donc d'éviter de surestimer l'intérêt des modèles complexes lorsque la série présente une forte persistance temporelle.

3.4. Performances des modèles Random Forest

Quatre modèles Random Forest sont estimés afin d'évaluer progressivement l'apport des variables explicatives. Le premier modèle utilise uniquement les retards de l'inflation énergétique. Le deuxième ajoute les retards du prix du Brent. Le troisième ajoute les retards du gaz naturel TTF. Et le quatrième intègre également les retards des matières premières importées hors énergie.

Tableau 9: Comparaison des performances des modèles Random Forest

Modèle	RMSE	MAE	R ²
RF1 : retards inflation	7.64	5.38	0.55
RF2 : retards inflation + Brent	6.58	5.18	0.67
RF3 : retards inflation + Brent + gaz	7.70	6.60	0.54
RF4 : retards inflation + Brent + gaz + matières premières	7.86	6.80	0.52

Le Tableau 9 montre que le modèle RF2 est le meilleur modèle Random Forest classique. L'ajout des retards du Brent améliore les performances par rapport au modèle RF1, qui utilise uniquement les retards de l'inflation énergétique. Le RMSE passe de 7,64 à 6,58, et le R² augmente de 0,55 à 0,67.

En revanche, l'ajout des retards du gaz TTF puis des matières premières hors énergie dégrade les performances. Le modèle RF3 obtient un RMSE de 7,70 et le modèle RF4 un RMSE de 7,86. Ce résultat montre que l'ajout de variables explicatives n'améliore pas automatiquement la prévision. Dans le cas du gaz TTF, cette dégradation peut s'expliquer par le caractère exceptionnel du choc gazier de 2021-2022. La variable présente des valeurs extrêmes très marquées, comme le montrent les statistiques descriptives, avec une forte asymétrie et une kurtosis élevée. Ces épisodes peuvent rendre la relation entre le prix du gaz et l'inflation énergétique instable. Le gaz capte bien une partie du choc de crise mais cette information n'est pas nécessairement utile pour prévoir l'ensemble de la période de test. Par ailleurs,

la transmission du prix de gros du gaz aux prix payés par les ménages peut être limitée ou retardée par les mécanismes de régulation et les mesures publiques, comme le bouclier tarifaire. Autrement dit, une hausse brutale du prix de gros du gaz ne se retrouve pas nécessairement immédiatement dans l'IPC énergie car les prix payés par les ménages peuvent être partiellement encadrés. Cette déconnexion temporaire peut expliquer pourquoi le gaz TTF, pourtant central dans la crise énergétique, n'améliore pas automatiquement les performances prédictives des modèles.

Le modèle RF2 apparaît donc comme le meilleur compromis parmi les Random Forest classiques. Il combine la dynamique passée de l'inflation énergétique avec l'information apportée par le Brent, qui constitue une variable économique directement liée aux prix des carburants et des produits pétroliers.

3.5. Apport du rolling window

La Random Forest rolling window est estimée afin de tenir compte de l'instabilité temporelle des relations économiques. Contrairement au modèle RF2 classique, estimé une seule fois sur l'ensemble de la période d'apprentissage, le modèle rolling window est réestimé progressivement sur une fenêtre mobile de 60 observations passées. Cette approche permet au modèle de s'adapter plus rapidement aux changements récents.

Tableau 10: Apport du rolling window par rapport au RF2 classique

Modèle	RMSE	MAE	R ²	Corrélation	Biais
RF2 classique	6.58	5.18	0.67	0.89	0.11
RF2 rolling window	4.95	4.06	0.81	0.91	1.61

Le Tableau 10 montre que l'approche rolling window améliore nettement les performances du modèle RF2. Le RMSE diminue de 6,58 à 4,95, tandis que le MAE passe de 5,18 à 4,06. Le R² augmente également, passant de 0,67 à 0,81. La corrélation entre les valeurs observées et prévues progresse légèrement, ce qui indique que le modèle rolling window suit mieux la dynamique de l'inflation énergétique.

Ce résultat est important parce-qu'il montre que la mise à jour progressive du modèle permet de mieux s'adapter à une période instable. Dans le cas de l'inflation énergétique, les relations entre les variables peuvent changer rapidement sous l'effet de chocs économiques ou géopolitiques. Une estimation fixe sur une période ancienne peut donc être moins adaptée qu'un modèle réentraîné régulièrement sur des observations récentes.

Cependant, le RF2 rolling window ne dépasse pas le modèle naïf. Cela signifie que, même avec une stratégie d'adaptation temporelle, la persistance immédiate de l'inflation énergétique reste

l'information la plus efficace sur la période de test. Le rolling window améliore donc fortement la Random Forest mais ne suffit pas à surpasser la référence naïve.

3.6. Comparaison statistique des modèles : test de Diebold-Mariano

Les indicateurs de performance permettent de classer les modèles mais ils ne suffisent pas toujours à déterminer si les différences observées sont statistiquement significatives. Pour cette raison, des tests de Diebold-Mariano sont réalisés. Ces tests comparent les erreurs de prévision de deux modèles. L'hypothèse nulle correspond à une égalité de performance prédictive.

Tableau 11: Tests de Diebold-Mariano entre les principaux modèles

Comparaison	Statistique DM	p-value	Conclusion
RF2 vs Naïf	2.950	0.005	Différence significative
RF2 vs ARIMA	-3.700	0.001	Différence significative
RF2 vs ARIMA corrigé	-3.700	0.001	Différence significative
RF2 vs ARMAX	-0.692	0.492	Différence non significative
RF2 vs Régression linéaire	-0.848	0.401	Différence non significative
RF2 vs RF2 pondéré	-1.110	0.274	Différence non significative
RF2 vs RF2 rolling window	2.120	0.039	Différence significative
RF2 pondéré vs Naïf	2.960	0.005	Différence significative
RF2 rolling window vs Naïf	2.630	0.012	Différence significative
ARMAX vs Naïf	3.440	0.001	Différence significative

Le Tableau 11 confirme plusieurs résultats importants. Premièrement, le modèle RF2 est significativement différent du modèle naïf. Comme le modèle naïf présente de meilleures performances, cette différence indique que RF2 ne parvient pas à dépasser la référence naïve sur la période de test.

Deuxièmement, RF2 est significativement meilleur que les modèles ARIMA et ARIMA corrigé. Cela montre que l'intégration des retards de l'inflation énergétique et du Brent apporte une information utile par rapport à une approche univariée simple.

Troisièmement, la différence entre RF2 et ARMAX n'est pas significative. Même si RF2 présente des indicateurs légèrement meilleurs que le modèle ARMAX, le test ne permet pas de conclure à une supériorité statistiquement nette. Ce résultat invite donc à nuancer l'interprétation. La Random Forest classique améliore certains indicateurs mais l'écart avec le modèle linéaire dynamique reste limité. Ce résultat confirme l'intérêt du test de Diebold-Mariano. Il permet de nuancer les conclusions lorsque les indicateurs de performance semblent favorables à un modèle mais que l'écart statistique entre les erreurs de prévision reste insuffisant (Diebold et Mariano, 1995).

Enfin, le test indique une différence significative entre RF2 et RF2 rolling window. Ce résultat confirme que l'approche rolling window apporte une amélioration statistiquement significative par rapport à la Random Forest classique. Toutefois, RF2 rolling window reste également significativement différent du modèle naïf, qui conserve les meilleures performances globales.

3.7. Analyse graphique des prévisions

La comparaison des indicateurs de performance est complétée par une analyse graphique des prévisions. L'objectif est d'observer si les modèles parviennent à reproduire la trajectoire de l'inflation énergétique sur la période de test, notamment lors du pic de 2022 puis de la phase de désinflation.




Figure 6: Prévisions de l'inflation énergétique sur la période de test

La Figure 6 montre que la période de test est difficile à prévoir pour la plupart des modèles. Les modèles peinent particulièrement à reproduire parfaitement le pic d'inflation de 2022 et les retournements rapides observés ensuite. Cette difficulté est cohérente avec le caractère exceptionnel de la crise énergétique.

Le modèle naïf suit de près la dynamique observée ce qui confirme les résultats du tableau de performance. La Random Forest rolling window reproduit également mieux la trajectoire observée que le RF2 classique et le modèle ARMAX. Le modèle ARIMA apparaît moins adapté car il ne parvient pas à capter correctement l'ampleur des variations observées sur la période de test.

Cette analyse graphique confirme donc que les meilleures performances sont obtenues par les modèles capables de s'adapter rapidement à la dynamique récente de la série. Toutefois, aucun modèle ne permet de prévoir parfaitement et exactement les ruptures brutales et cela souligne les limites de la prévision dans un contexte de chocs économiques et géopolitiques.

3.8. Analyse des erreurs de prévision

L'analyse des erreurs permet d'identifier les périodes où les modèles se trompent le plus. Elle est particulièrement utile dans ce mémoire car la période de test comprend des épisodes de forte instabilité. L'objectif n'est donc pas seulement de mesurer l'erreur moyenne mais aussi de comprendre à quelles dates les erreurs sont les plus importantes.

L'analyse du modèle RF2 classique montre que ses erreurs les plus fortes se concentrent principalement autour du choc énergétique de 2022. En particulier, les mois de mars, mai, juin et juillet 2022 correspondent à des erreurs importantes. Le modèle sous-estime alors fortement l'inflation énergétique observée. Cette difficulté traduit la capacité limitée du modèle à anticiper l'ampleur du choc énergétique.

Le modèle RF2 rolling window réduit ces erreurs extrêmes. L'erreur absolue moyenne passe de 5,18 pour le RF2 classique à 4,06 pour le RF2 rolling window. L'écart-type des erreurs diminue également, passant de 6,66 à 4,73. Cela montre que le rolling window permet non seulement d'améliorer l'erreur moyenne mais aussi de réduire la dispersion des erreurs.

Tableau 12: Principales erreurs du modèle RF2 rolling window

Date	Observé	Prévision	Erreur	Erreur absolue
2022-03	29.22	17.70	11.51	11.51
2023-03	4.89	15.50	-10.60	10.60
2025-02	-5.81	4.20	-10.00	10.00
2022-09	17.92	27.00	-9.03	9.03
2023-09	11.87	4.31	7.56	7.56
2022-06	33.05	26.17	6.88	6.88
2023-08	6.80	-0.01	6.80	6.80
2023-06	-3.00	3.77	-6.77	6.77
2022-08	22.74	28.96	-6.22	6.22
2022-12	15.12	21.06	-5.94	5.94

Le Tableau 12 montre que malgré l'amélioration apportée par le rolling window, certaines erreurs restent importantes. En mars 2022, le modèle sous-estime encore l'inflation énergétique. À l'inverse, en mars 2023 et février 2025, il la surestime fortement. Cela indique que le modèle s'adapte mieux aux phases de hausse, mais peut conserver des prévisions trop élevées lorsque l'inflation énergétique ralentit ou devient négative.

Cette analyse confirme que les erreurs les plus fortes correspondent souvent à des périodes de retournement ou de changement de régime. La prévision de l'inflation énergétique reste donc particulièrement difficile lorsque la dynamique de la série change rapidement.

3.9. Importance des variables dans la Random Forest

L'un des intérêts de la Random Forest est qu'elle permet d'identifier les variables qui contribuent le plus à la qualité des prévisions. L'importance des variables constitue un outil utile d'interprétation, même si elle ne doit pas être interprétée comme une relation causale directe. L'importance est mesurée ici à partir de l'indicateur $\%IncMSE$ (plus cette valeur est élevée, plus la variable est importante pour réduire l'erreur de prévision du modèle). L'importance des variables dans une Random Forest doit toutefois être interprétée comme un indicateur prédictif et non comme une preuve de causalité économique directe (James et al., 2021).




Figure 7: Importance des variables dans le modèle Random Forest 2

La Figure 7 montre que les variables les plus importantes du modèle RF2 sont les retards de l'inflation énergétique et les retards du Brent. Ce résultat est cohérent avec les performances obtenues précédemment, le meilleur modèle Random Forest classique est celui qui combine la dynamique passée de l'inflation énergétique avec l'information issue du marché pétrolier.

Ce résultat rejoint les tests exploratoires de sélection de variables présentés en annexe. Le Best Subset retient un modèle très parcimonieux centré sur les retards de l'inflation énergétique, tandis que GETS conserve également certaines variables de marché, notamment le Brent et les matières premières hors énergie. Ces résultats confirment que la dynamique passée de l'inflation énergétique joue un rôle central, même si certaines variables économiques peuvent apporter une information complémentaire.

L'importance élevée des retards de l'inflation énergétique confirme la forte inertie de la variable cible. Le Brent joue également un rôle important, ce qui est cohérent avec son lien économique direct avec les carburants et les produits pétroliers. En revanche, les résultats précédents

montrent que l'ajout du gaz TTF et des matières premières hors énergie ne permet pas d'améliorer les performances sur la période de test principale.

3.10. Robustesse des résultats

Plusieurs analyses de robustesse sont réalisées afin d'évaluer la stabilité des résultats. La première consiste à estimer le modèle RF2 sur 100 graines aléatoires différentes. Cette étape est importante car la Random Forest repose sur des tirages aléatoires dans la construction des arbres. Des performances très variables selon les graines indiqueraient une instabilité du modèle.

Les résultats montrent que les performances du RF2 sont relativement stables selon les graines (Tableau 28). Le RMSE moyen est égal à 6,70, avec un minimum de 6,52 et un maximum de 6,90. L'écart-type du RMSE est de 0,08. Le MAE moyen est égal à 5,25, avec un minimum de 5,03 et un maximum de 5,47. L'écart-type du MAE est également faible, égal à 0,08. Ces résultats indiquent que les performances du RF2 ne dépendent pas fortement du choix de la graine

La deuxième analyse de robustesse consiste à modifier la période de test. Dans l'analyse principale, la période de test commence en janvier 2022. Ce choix est exigeant car il place le choc énergétique de 2022 hors de l'échantillon d'apprentissage. Dans le test de robustesse, la période d'apprentissage est prolongée jusqu'en décembre 2022, et la période de test commence en janvier 2023.

Tableau 13: Test de robustesse avec période de test à partir de 2023

Modèle	RMSE	MAE	R ²
ARMAX	13.13	10.32	-3.37
RF1 : retards inflation	5.06	3.76	0.35
RF2 : retards inflation + Brent	6.59	5.77	-0.10
RF3 : retards inflation + Brent + gaz	9.68	8.67	-1.38
RF4 : retards inflation + Brent + gaz + matières premières	11.85	10.75	-2.56

Le Tableau 13 montre que les résultats sont sensibles au choix de la période de test. Lorsque l'année 2022 est intégrée à l'échantillon d'apprentissage et que la période de test commence en janvier 2023, le meilleur modèle devient RF1, fondé uniquement sur les retards de l'inflation énergétique. Il obtient un RMSE de 5,06 et un MAE de 3,76.

Ce résultat peut s'expliquer par le fait que l'année 2022 correspond à un choc énergétique majeur. Lorsque cette année est incluse dans l'apprentissage, le modèle observe une partie de la dynamique de crise. Sur la période 2023-2025, davantage marquée par la désinflation, les retards de l'inflation énergétique suffisent mieux à prévoir l'évolution de la série.

À l'inverse, l'ajout du Brent, du gaz TTF et des matières premières hors énergie dégrade les performances dans ce test. Cela confirme que l'apport des variables explicatives dépend du contexte conjoncturel. Les variables de marché peuvent être utiles pendant certaines phases, mais elles ne garantissent pas une amélioration systématique de la prévision.

3.11. Synthèse des résultats empiriques

Les résultats empiriques répondent à la problématique du mémoire de manière nuancée. Il est possible de prévoir partiellement l'inflation énergétique en France mais les performances dépendent fortement du modèle retenu, de la période de test et de la dynamique économique observée.

Le modèle naïf obtient les meilleures performances globales. Ce résultat souligne la forte inertie de l'inflation énergétique calculée en glissement annuel. Il montre également qu'un modèle très simple peut être difficile à dépasser lorsque la variable cible présente une forte persistance.

Parmi les modèles complexes, la Random Forest rolling window est la plus performante. Elle améliore nettement le modèle RF2 classique et cela montre que la mise à jour progressive du modèle permet de mieux s'adapter à une période instable. Néanmoins elle ne dépasse pas le modèle naïf ce qui limite la portée de cette amélioration.

Le modèle RF2 classique reste néanmoins intéressant. Il obtient de meilleures performances que les modèles ARIMA et présente des indicateurs légèrement meilleurs que le modèle ARMAX. Mais les tests de Diebold-Mariano montrent que l'écart entre RF2 et ARMAX n'est pas statistiquement significatif. Il faut donc éviter de conclure à une supériorité nette de la Random Forest classique sur le modèle linéaire dynamique.

L'importance des variables montre que les retards de l'inflation énergétique et les retards du Brent jouent un rôle central dans la prévision. Ce résultat est cohérent avec l'idée que l'inflation énergétique dépend à la fois de sa propre dynamique passée et des évolutions récentes du marché pétrolier.

Enfin, les analyses de robustesse montrent que les résultats sont sensibles au choix de la période d'évaluation. Lorsque l'année 2022 est intégrée à l'apprentissage, le modèle RF1 devient le plus performant sur la période 2023-2025. Cela confirme que les relations entre les variables ne sont pas totalement stables dans le temps.

Au total, la réponse à la problématique est donc prudente. Les prix du pétrole, du gaz naturel et des matières premières peuvent contribuer à prévoir l'inflation énergétique, mais leur apport dépend du contexte. La forte inertie de la variable cible et les chocs économiques et géopolitiques limitent la capacité des modèles à produire des prévisions parfaitement fiables. La Random Forest apporte une flexibilité utile, notamment en rolling window, mais elle ne supprime pas l'incertitude propre à l'inflation énergétique.

Tableau 14: Synthèse des principaux résultats empiriques

Résultat	Interprétation
Le modèle naïf obtient les meilleures performances globales	L'inflation énergétique présente une forte inertie en glissement annuel.
La Random Forest rolling window est le meilleur modèle complexe	La réestimation progressive du modèle permet de mieux s'adapter aux changements récents.
Le modèle RF2 classique reste utile	Les retards de l'inflation énergétique et du Brent apportent une information prédictive.
RF2 n'est pas significativement meilleur qu'ARMAX	La supériorité de la Random Forest classique sur le modèle linéaire dynamique doit être nuancée.
L'ajout du gaz et des matières premières dégrade les performances des RF classiques	Ajouter davantage de variables ne garantit pas une meilleure prévision hors échantillon.
Les retards de l'inflation et du Brent sont les variables les plus importantes	La dynamique passée de l'inflation et le prix du pétrole jouent un rôle central dans la prévision.
Les erreurs les plus fortes apparaissent lors des retournements	Les chocs énergétiques et les changements rapides de régime restent difficiles à anticiper.
Les résultats sont sensibles à la période de test	L'apport des variables explicatives dépend du contexte économique et de la période évaluée.

Discussion

Les résultats obtenus permettent de répondre à la problématique de manière nuancée. L'inflation énergétique en France peut être partiellement prévue à partir de sa dynamique passée et de certaines variables liées aux marchés de l'énergie mais les performances restent fortement dépendantes de la période d'évaluation et du contexte économique. La période de test retenue, allant de janvier 2022 à septembre 2025, constitue un cadre particulièrement exigeant, puisqu'elle inclut le choc énergétique de 2022, puis une phase de désinflation.

Le premier résultat important est la très bonne performance du modèle naïf. Ce modèle, qui prévoit l'inflation énergétique du mois courant par sa valeur observée le mois précédent, obtient les meilleurs indicateurs sur la période de test. Il présente le RMSE et le MAE les plus faibles, ainsi que le R^2 prédictif le plus élevé. Ce résultat peut sembler surprenant car il s'agit du modèle le plus simple. Il s'explique toutefois par la forte inertie de l'inflation énergétique calculée en glissement annuel. Deux mois consécutifs partagent une partie importante de la même information ce qui rend la valeur du mois précédent très prédictive.

Ce résultat constitue un point essentiel du mémoire. Il montre qu'un modèle complexe ne doit pas seulement être comparé à un modèle linéaire de référence, mais aussi à une règle de prévision très simple. Dans le cas étudié, la persistance de l'inflation énergétique est suffisamment forte pour rendre le modèle naïf difficile à dépasser. Cela ne signifie pas que les variables économiques sont inutiles, mais cela montre que leur apport prédictif doit être évalué avec prudence.

Ce résultat ne remet pas en cause l'intérêt d'avoir mobilisé la Random Forest mais il en précise ces limites. L'objectif du mémoire était justement de tester si une méthode plus flexible pouvait dépasser les modèles classiques dans un contexte instable. Le fait que la Random Forest rolling window améliore nettement la Random Forest classique montre que cette approche apporte une information utile, même si elle ne suffit pas à battre la référence naïve. Le résultat principal n'est donc pas un échec méthodologique mais un enseignement empirique. Dans le cas de l'inflation énergétique en glissement annuel, la persistance de la série reste plus prédictive que l'ajout de relations non linéaires complexes.

Parmi les modèles plus complexes, la Random Forest rolling window apparaît comme le meilleur modèle. Elle améliore nettement le modèle RF2 classique, avec un RMSE plus faible, un MAE plus faible et un R^2 plus élevé. Ce résultat montre l'intérêt d'une méthode réestimée progressivement sur une fenêtre mobile d'observations récentes. Dans un contexte instable, les relations entre les variables peuvent évoluer rapidement. Une estimation fixe sur une période ancienne peut donc être moins adaptée qu'un modèle régulièrement mis à jour.

Le modèle RF2 classique reste néanmoins intéressant. Il combine les retards de l'inflation énergétique et les retards du Brent. Ses performances sont meilleures que celles des modèles ARIMA et légèrement meilleures que celles du modèle ARMAX. Cependant, le test de Diebold-Mariano montre que la différence entre RF2 et ARMAX n'est pas statistiquement significative. Il faut donc éviter de conclure à une supériorité nette de la Random Forest classique sur le

modèle linéaire dynamique. L'apport de la Random Forest existe mais il reste limité dans sa version classique.

L'analyse des modèles Random Forest montre également que l'ajout de variables explicatives n'améliore pas automatiquement les performances. Le modèle RF2 est meilleur que RF1, ce qui suggère que les retards du Brent apportent une information utile. En revanche, l'ajout du gaz naturel TTF puis des matières premières hors énergie dégrade les résultats. Ce point est important car il montre qu'un modèle plus complet n'est pas nécessairement plus performant. Dans un échantillon de taille limitée, certaines variables peuvent ajouter du bruit ou rendre le modèle moins efficace en prévision hors échantillon.

L'analyse de l'importance des variables confirme le rôle central des retards de l'inflation énergétique et des retards du Brent. Les retards de l'inflation traduisent l'inertie de la variable cible, tandis que le Brent apporte une information économique liée aux carburants, au fioul domestique et aux produits pétroliers. Ce résultat est cohérent avec la logique économique développée dans la première partie du mémoire. En revanche, l'importance des variables ne doit pas être interprétée comme une relation causale directe. Elle indique seulement quelles variables contribuent le plus à la qualité prédictive du modèle.

Les erreurs de prévision montrent que les modèles sont particulièrement mis en difficulté lors des périodes de retournement. Le RF2 classique sous-estime fortement l'inflation énergétique au moment du choc de 2022, surtout au printemps et à l'été. Le RF2 rolling window réduit ces erreurs extrêmes, mais il continue de présenter des erreurs importantes à certaines dates, notamment lorsque l'inflation ralentit ou devient négative. Cela montre que les modèles ont du mal à anticiper les changements rapides de régime. Les travaux sur les prix du gaz naturel montrent également que les marchés énergétiques peuvent réagir fortement à des chocs climatiques, géopolitiques ou d'incertitude, ce qui limite la capacité des modèles statistiques à anticiper les ruptures brutales (Chen, Hartley et Lan, 2023 ; Su et al., 2023).

Les tests de robustesse confirment la sensibilité des résultats à la période d'évaluation. Lorsque l'année 2022 est intégrée à l'échantillon d'apprentissage et que la période de test commence en janvier 2023, le meilleur modèle devient RF1, fondé uniquement sur les retards de l'inflation énergétique. Ce résultat signifie que l'apport des variables de marché dépend du contexte. Le Brent semble utile dans la période de choc, mais une fois l'épisode de 2022 intégré à l'apprentissage, la dynamique propre de l'inflation énergétique devient plus déterminante.

Ce mémoire présente plusieurs apports. Il montre d'abord la difficulté de prévoir l'inflation énergétique sur une période récente marquée par des chocs majeurs. Il met ensuite en évidence l'importance de comparer les modèles complexes à des références simples, comme le modèle naïf. Enfin, il montre que les méthodes d'apprentissage automatique peuvent apporter une flexibilité utile, notamment lorsqu'elles sont utilisées dans une logique de rolling window.

Plusieurs limites doivent toutefois être soulignées. La première concerne la taille de l'échantillon. La base contient 123 observations mensuelles, ce qui reste relativement limité pour estimer des modèles de machine learning. Cette contrainte impose de rester prudent dans l'interprétation des performances obtenues.

Une deuxième limite concerne la profondeur historique des données. La série du gaz naturel TTF limite la période d'analyse à partir de 2015. Il n'est donc pas possible d'étudier une période beaucoup plus longue sans modifier les sources de données ou reconstruire certaines séries.

Une troisième limite tient au choix des variables explicatives. La base empirique repose principalement sur des séries issues de l'INSEE, ce qui permet de disposer de données mensuelles homogènes et directement comparables. Les publications de la Banque de France sont mobilisées pour éclairer le contexte macroéconomique et institutionnel, mais les données Banque de France ne sont pas intégrées comme variables explicatives dans les modèles, afin de conserver une base homogène composée de séries mensuelles directement comparables entre elles. Une extension possible consisterait à enrichir la base avec des indicateurs issus de la Banque de France, par exemple des indicateurs conjoncturels, financiers ou liés aux anticipations d'inflation. Le mémoire se concentre sur le Brent, le gaz TTF et les matières premières hors énergie. Or d'autres variables pourraient également influencer l'inflation énergétique, comme le taux de change euro-dollar, les taxes sur l'énergie, les prix de gros de l'électricité, les mesures publiques de protection des ménages, ou encore les décisions de régulation. Le Brent étant exprimé en euros, l'effet du taux de change est pris en compte indirectement, mais il n'est pas étudié comme variable séparée.

Enfin, la Random Forest présente elle-même certaines limites. Elle permet de capter des relations non linéaires et de mesurer l'importance des variables, mais elle reste moins directement interprétable qu'un modèle linéaire. Cette prudence rejoint les limites généralement associées aux méthodes d'apprentissage automatique, elles peuvent améliorer la performance prédictive, mais leur efficacité dépend de la taille de l'échantillon, de la qualité des données et de la stabilité des relations économiques étudiées (James et al., 2021 ; Medeiros et al., 2021). Elle ne fournit pas une relation simple entre chaque variable explicative et l'inflation énergétique. De plus, comme toute méthode statistique, elle reste dépendante des données utilisées pour l'apprentissage et peut être mise en difficulté face à des chocs inédits.

Il faut toutefois souligner que le modèle naïf reste imparfait. Même s'il obtient les meilleures performances relatives, son sMAPE demeure élevé, ce qui montre que la prévision de l'inflation énergétique reste difficile en valeur absolue. Autrement dit, le modèle naïf est le meilleur parmi les modèles comparés, mais il ne permet pas de prévoir parfaitement les variations de l'inflation énergétique.

Sur le plan de l'aide à la décision, les résultats appellent à utiliser les modèles de prévision de l'inflation énergétique comme des outils d'appui plutôt que comme des instruments de prévision automatique. La bonne performance du modèle naïf montre qu'une référence simple, fondée sur l'inertie de la série, doit systématiquement être conservée dans le suivi conjoncturel. Les modèles plus complexes, comme la Random Forest en rolling window, peuvent être utilisés en complément, notamment lorsqu'il est nécessaire d'intégrer rapidement les informations les plus récentes. En revanche, les résultats montrent qu'en période de choc énergétique, les prévisions doivent être interprétées avec prudence et accompagnées d'une analyse économique du contexte.

Ces résultats conduisent également à plusieurs recommandations pratiques. Pour un suivi régulier de l'inflation énergétique, il paraît préférable de comparer systématiquement les modèles complexes à une prévision naïve, afin de vérifier que leur gain prédictif est réel. Il est aussi utile de privilégier des modèles réestimés régulièrement, comme l'approche rolling window, car les relations entre les prix de marché et l'inflation peuvent évoluer rapidement. Enfin, les variables de marché, comme le Brent ou le gaz naturel, doivent être utilisées comme des signaux complémentaires plutôt que comme des déterminants mécaniques de l'inflation énergétique.

Ces limites ouvrent plusieurs pistes d'amélioration. Une première piste consisterait à enrichir la base de données avec davantage de variables explicatives, notamment le taux de change, les prix de gros de l'électricité, les taxes énergétiques ou des indicateurs de politiques publiques. Une deuxième piste serait de comparer la Random Forest avec d'autres méthodes d'apprentissage automatique, comme le gradient boosting, XGBoost ou les réseaux de neurones. Une troisième piste consisterait à utiliser une validation temporelle plus complète, avec plusieurs fenêtres de test successives, afin d'évaluer plus finement la stabilité des modèles dans le temps.

Pour conclure, la discussion montre que la prévision de l'inflation énergétique reste un exercice complexe. Les modèles peuvent capter une partie de la dynamique observée, mais ils ne permettent pas de prévoir parfaitement les ruptures liées aux crises économiques et géopolitiques. Cette limite est au cœur de la problématique du mémoire.

Conclusion

Ce mémoire avait pour objectif d’analyser et de prévoir l’inflation énergétique en France à partir de variables liées aux marchés de l’énergie et aux matières premières. La problématique retenue était la suivante : peut-on réellement prévoir l’inflation énergétique en France à partir des prix du pétrole, du gaz naturel et des matières premières, alors que cette inflation est fortement dépendante de chocs économiques et géopolitiques ?

L’analyse descriptive a d’abord montré que l’inflation énergétique est une variable particulièrement volatile. La période étudiée, allant de juillet 2015 à septembre 2025, met en évidence plusieurs phases distinctes : une période de baisse ou de progression modérée des prix de l’énergie, une forte hausse à partir de 2021, un pic marqué en 2022, puis une phase de désinflation. Ces évolutions confirment que l’inflation énergétique est fortement exposée aux tensions sur les marchés internationaux et aux chocs économiques.

Sur le plan méthodologique, plusieurs modèles ont été mobilisés afin de comparer différentes approches de prévision. Les modèles de référence, comme le modèle naïf, l’ARIMA et la régression linéaire, permettent d’évaluer les performances de méthodes simples. Le modèle ARMAX est utilisé comme modèle linéaire dynamique car il combine des variables explicatives économiques et une structure temporelle dans les erreurs. La Random Forest est ensuite mobilisée comme méthode principale d’apprentissage automatique afin de prendre en compte d’éventuelles relations non linéaires entre les variables.

Les résultats empiriques montrent d’abord que le modèle naïf obtient les meilleures performances globales sur la période de test principale. Ce résultat souligne la forte inertie de l’inflation énergétique calculée en glissement annuel. Il montre qu’une prévision très simple, fondée sur la valeur du mois précédent, peut être difficile à dépasser lorsque la variable cible présente une forte persistance.

Parmi les modèles complexes, la Random Forest rolling window est la plus performante. Elle améliore nettement la Random Forest classique, ce qui montre l’intérêt d’une réestimation progressive du modèle dans un contexte instable. Cette approche permet au modèle de s’adapter davantage aux observations récentes. Toutefois, elle ne dépasse pas le modèle naïf, ce qui limite la portée de l’amélioration.

Le modèle RF2 classique, qui utilise les retards de l’inflation énergétique et les retards du Brent, reste néanmoins utile. Il obtient de meilleures performances que les modèles ARIMA et présente des indicateurs légèrement meilleurs que le modèle ARMAX. Toutefois, les tests de Diebold-Mariano montrent que l’écart entre RF2 et ARMAX n’est pas statistiquement significatif. Il n’est donc pas possible d’affirmer que la Random Forest classique est nettement supérieure au modèle linéaire dynamique.

L’analyse de l’importance des variables montre que les retards de l’inflation énergétique et les retards du Brent jouent un rôle central dans la prévision. Ce résultat confirme que l’inflation énergétique dépend à la fois de sa propre dynamique passée et des évolutions récentes du

marché pétrolier. En revanche, l'ajout du gaz naturel TTF et des matières premières hors énergie n'améliore pas les performances dans les modèles Random Forest classiques.

La réponse à la problématique est donc prudente. Il est possible de prévoir partiellement l'inflation énergétique en France, mais cette prévision repose principalement sur l'inertie de la variable cible. Les prix du pétrole, du gaz naturel et des matières premières peuvent apporter une information complémentaire, mais leur contribution dépend du contexte conjoncturel et de la période étudiée. Les chocs économiques et géopolitiques limitent fortement la capacité des modèles à anticiper les ruptures brutales.

Ce mémoire montre ainsi l'intérêt des méthodes de prévision pour analyser l'inflation énergétique, mais aussi leurs limites. Les modèles statistiques peuvent reproduire une partie des dynamiques observées, en particulier lorsque les relations restent relativement stables. En revanche, ils sont moins performants face aux changements rapides de régime, comme ceux observés pendant la crise énergétique de 2022. Cette conclusion rejoint l'idée selon laquelle les méthodes de prévision doivent être évaluées non seulement à partir de leurs performances statistiques mais aussi à partir de leur capacité à rester robustes dans des contextes économiques instables (Hyndman et Athanasopoulos, 2021 ; Medeiros et al., 2021).

D'un point de vue opérationnel, ce mémoire conduit donc à recommander une utilisation combinée des modèles. Le modèle naïf peut servir de référence simple et robuste pour le suivi de court terme, tandis que les modèles intégrant des variables de marché peuvent être mobilisés pour enrichir l'analyse économique. La Random Forest rolling window apparaît particulièrement utile lorsque l'on souhaite tenir compte des observations récentes et de l'instabilité des relations économiques. Toutefois, les prévisions doivent toujours être interprétées à la lumière du contexte conjoncturel, notamment en période de crise énergétique ou de retournement rapide des prix.

Pour prolonger ce travail, plusieurs pistes pourraient être envisagées. Il serait possible d'enrichir la base avec d'autres variables, comme les prix de l'électricité, les taxes énergétiques, les mesures publiques ou le taux de change. Il serait également pertinent de comparer la Random Forest avec d'autres méthodes d'apprentissage automatique, comme le gradient boosting ou les réseaux de neurones. Enfin, une validation temporelle plus complète permettrait d'évaluer les performances des modèles sur plusieurs périodes de test et de mieux mesurer leur stabilité.

Pour finir, l'inflation énergétique peut être anticipée partiellement, mais elle reste difficile à prévoir parfaitement. Cette difficulté ne traduit pas seulement une limite statistique, elle reflète aussi la nature économique de la variable étudiée, fortement dépendante de marchés internationaux, de décisions politiques et de chocs géopolitiques. Le principal enseignement du mémoire est donc que la prévision de l'inflation énergétique doit être interprétée avec prudence, en combinant performance statistique, logique économique et analyse du contexte.

Bibliographie

Ouvrages

Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.

Hyndman, R. J. et Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3e éd.). OTexts.

James, G., Witten, D., Hastie, T. et Tibshirani, R. (2021). *An Introduction to Statistical Learning: With Applications in R* (2e éd.). Springer.

Stock, J. H. et Watson, M. W. (2019). *Introduction to Econometrics* (4e éd.). Pearson.

Articles de revues scientifiques

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.

Chen, Y., Hartley, P. R. et Lan, Y. (2023). Temperature, storage, and natural gas futures prices. *Journal of Futures Markets*.

Diebold, F. X. et Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253-263.

Medeiros, M. C., Vasconcelos, G. F. R., Veiga, A. et Zilberman, E. (2021). Forecasting inflation in a data-rich environment: The benefits of machine learning methods. *Journal of Business & Economic Statistics*, 39(1), 98-119.

Shen, Y., Sun, X., Ji, Q. et Zhang, D. (2023). Climate events matter in the global natural gas market. *Energy Economics*, 125, 106887.

Su, C. W., Qin, M., Chang, H. L. et Țăran, A. M. (2023). Which risks drive European natural gas bubbles? Novel evidence from geopolitics and climate. *Resources Policy*, 81, 103381.

Ressources internet

Banque de France. (2022a). *Projections macroéconomiques — Juin 2022*. Banque de France.

Banque de France. (2022b). *Projections macroéconomiques — Septembre 2022*. Banque de France.

Banque de France. (2022c). *Projections macroéconomiques — Décembre 2022*. Banque de France.

Banque de France. (2024). *Bouclier tarifaire sur les prix de l'énergie en France : quel bilan ?* Bulletin de la Banque de France, 253/4.

Banque de France. (2025). *Suivre l'évolution des prix alimentaires dans la zone euro en temps réel : les leçons de la période 2022-2024*. Bulletin de la Banque de France, 259/1.

INSEE. (2025). *Indice des prix à la consommation — Énergie*. Institut national de la statistique et des études économiques.

INSEE. (2025). *Prix du pétrole Brent en euros*. Institut national de la statistique et des études économiques.

INSEE. (2025). *Prix du gaz naturel TTF en euros par mégawattheure*. Institut national de la statistique et des études économiques.

INSEE. (2025). *Indice des matières premières importées hors énergie en euros*. Institut national de la statistique et des études économiques.

INSEE. (2025). *Indice des prix à la consommation : définition, méthode et données*. Institut national de la statistique et des études économiques.

Packages R

dplyr. (manipulation et la transformation des données)

forecast. (estimation des modèles ARIMA et les outils de prévision)

ggplot2. (production des graphiques)

janitor. (nettoyage et l'harmonisation des noms de variables)

kableExtra. (mise en forme des tableaux dans le document)

knitr. (intégration des résultats dans le document Quarto)

lubridate. (traitement des dates)

randomForest. (estimation des modèles Random Forest)

readr. (importation des fichiers de données)

stringr. (traitement des chaînes de caractères)

tseries.(tests statistiques appliqués aux séries temporelles)

tsoutliers. (analyse des valeurs atypiques dans les séries temporelles)

yardstick. (calcul des indicateurs de performance prédictive)

Cours Master ECAP

Darné, O. (2025-2026). *Techniques de prévision et conjoncture*. Master 1 Économétrie et Statistique, parcours Économétrie appliquée, IAE-Nantes Université.

Sevi, B. (2025-2026). *Séries temporelles univariées*. Master 1 Économétrie et Statistique, parcours Économétrie appliquée, IAE-Nantes Université.

Ait-Youcef, C. (2025-2026). *Analyse de données et descriptives*. Master 1 Économétrie et Statistique, parcours Économétrie appliquée, IAE-Nantes Université.

Machefer, M. (2025-2026). *Introduction au logiciel R, Biostatistique*. Master 1 Économétrie et Statistique, parcours Économétrie appliquée, IAE-Nantes Université.

Duc, J. (2025-2026). *Évaluation des actifs financiers*. Master 1 Économétrie et Statistique, parcours Économétrie appliquée, IAE-Nantes Université.

Floc Hlay, S. (2025-2026). *Cours R avance et GitHub*. Master 1 Économétrie et Statistique, parcours Économétrie appliquée, IAE-Nantes Université.

Annexes

Annexe partie 1 : Environnement économique et présentation des variables



Figure 8: Annexe 1 — Évolution de l'indice des prix à la consommation de l'énergie




Figure 9: Annexe 2 — Inflation énergétique en France




Figure 10: Annexe 3 — Évolution du prix du pétrole Brent





Figure 11: Annexe 4 — Évolution du prix du gaz naturel TTF


Évolution de l'indice des matières premières importées hors énergie



Source : INSEE.

Figure 12: Annexe 5 — Évolution de l'indice des matières premières importées hors énergie

Évolution des principales variables utilisées dans l'analyse



Source : INSEE, avec calculs.

Figure 13: Annexe 6 — Évolution synthétique des principales variables de la base

Tableau 15: Annexe 7 — Présentation synthétique des variables mobilisées dans la première partie

Variable	Type	Unité	Rôle dans l'analyse	Source
IPC énergie	Indice	Base 2015	Sert au calcul de l'inflation énergétique	INSEE
Inflation énergétique	Variable cible	Pourcentage	Mesure l'évolution annuelle des prix de l'énergie	Calculs à partir de l'INSEE
Brent en euros	Variable explicative	Euros par baril	Capte les tensions sur le marché pétrolier	INSEE
Gaz naturel TTF	Variable explicative	Euros par mégawattheure	Capte les tensions sur le marché européen du gaz	INSEE
Matières premières hors énergie	Variable explicative de contexte	Indice en euros	Représente le contexte général des tensions sur les matières premières importées	INSEE
Retards de l'inflation	Variables dynamiques	Pourcentage	Captent l'inertie de l'inflation énergétique	Calculs
Retards du Brent, du gaz et des matières premières	Variables explicatives retardées	Selon la variable d'origine	Captent les délais de transmission vers les prix à la consommation	Calculs

Tableau 16: Annexe 8 — Statistiques descriptives des principales variables

variable	moyenne	ecart_type	minimum	maximum	skewness	kurtosis
Inflation énergétique	4.34	9.53	-11.01	33.05	0.75	3.15
Brent en euros	60.30	18.57	16.90	115.50	0.50	3.30
Gaz naturel TTF	36.22	38.51	4.90	236.00	2.78	11.72
Matières premières hors énergie	126.70	26.98	88.40	179.00	0.31	1.54




Figure 14: Annexe 9 — Distribution des principales variables

Tableau 17: Annexe 10 — Détection des points atypiques de l'inflation énergétique

date	type	coefhat	tstat	interpretation
2021-04	LS	23.21	13.04	Reprise post-Covid et tensions sur les marchés de l'énergie
2023-03	LS	-17.08	-9.36	Phase de désinflation énergétique après le pic de 2022
2016-07	LS	11.81	7.93	Rebond après la baisse des prix énergétiques
2022-04	LS	12.15	4.83	Choc énergétique lié à la crise européenne et à la guerre en Ukraine
2020-04	LS	-8.02	-4.75	Crise sanitaire et chute de la demande d'énergie
2015-07	LS	-5.41	-4.30	Début de période, niveau bas de l'inflation énergétique
2022-08	LS	-11.32	-4.14	Ajustement après le pic du choc énergétique
2019-01	LS	-4.77	-3.46	Ralentissement avant la crise sanitaire




Figure 15: Annexe 11 — Inflation énergétique observée et corrigée des points atypiques

Annexe partie 2 : Démarche méthodologique et tests complémentaires




Figure 16: Annexe 12 — Organigramme de la démarche méthodologique

Tableau 18: Annexe 13 — Tests de Ljung-Box sur les résidus des modèles ARX et ARMAX

Modèle	Retard	p-value	Interprétation
ARX	6	0.050	Autocorrélation limite
ARX	12	0.046	Autocorrélation significative
ARX	18	0.023	Autocorrélation significative
ARMAX	6	0.975	Pas d'autocorrélation
ARMAX	12	0.861	Pas d'autocorrélation
ARMAX	18	0.961	Pas d'autocorrélation

Tableau 19: Annexe 14 — Tests de stationnarité appliqués à l'inflation énergétique

Test	Hypothèse nulle	p-value	Interprétation
ADF	Présence d'une racine unitaire	0.658	L'hypothèse de racine unitaire n'est pas rejetée
KPSS	Stationnarité de la série	0.100	L'hypothèse de stationnarité n'est pas rejetée




Figure 17: Annexe 15 — Décomposition STL de l'inflation énergétique




Figure 18: Annexe 16 — ACF de l'inflation énergétique




Figure 19: Annexe 17 — PACF de l'inflation énergétique

Tableau 20: Annexe 18 — Sélection de variables par Best Subset

nb_variables	adjr2	bic	cp
1	0.897	-270.618	20.885
2	0.902	-273.853	14.026
3	0.904	-272.265	12.636
4	0.907	-272.341	9.664
5	0.909	-270.787	8.456
6	0.909	-267.921	8.581
7	0.910	-265.460	8.355
8	0.911	-263.253	7.938
9	0.911	-258.976	9.447
10	0.911	-254.654	11.000

Tableau 21: Annexe 19 — Résultat de la sélection GETS

Variable	Coefficient	Erreur-type	Statistique t	p-value
Inflation retard 1	0.832	0.063	13.248	0.000
Inflation retard 6	0.074	0.058	1.286	0.201
Inflation retard 12	-0.142	0.051	-2.810	0.006
Brent retard 1	0.099	0.047	2.117	0.036
Brent retard 3	-0.050	0.039	-1.271	0.206
Gaz TTF retard 1	-0.008	0.015	-0.518	0.606
Gaz TTF retard 3	0.018	0.014	1.310	0.193
Matières premières retard 1	0.091	0.047	1.955	0.053
Matières premières retard 3	-0.107	0.049	-2.173	0.032

Tableau 22: Annexe 20 — Logiciels et packages utilisés

Logiciel ou package	Utilisation
R	Traitement des données, estimation des modèles et génération des résultats
RStudio	Environnement de travail
Quarto	Rédaction et génération du document PDF
dplyr	Manipulation et transformation des données
ggplot2	Production des graphiques
forecast	Estimation des modèles ARIMA et tests de prévision
randomForest	Estimation des modèles Random Forest
yardstick	Calcul des indicateurs de performance
tseries	Tests de stationnarité
tsoutliers	Détection d'outliers dans les séries temporelles
knitr et kableExtra	Mise en forme des tableaux

Annexe partie 3 : Résultats complémentaires et diagnostics de prévision

Tableau 23: Annexe 21 — Tableau complet des performances des modèles

Modèle	RMSE	MAE	R ²	Corrélation	Biais	sMAPE	MASE
Naïf	4.05	3.10	0.87	0.94	0.51	56.2	0.99
RF2 rolling window	4.95	4.06	0.81	0.91	1.61	69.3	1.29
RF2	6.58	5.18	0.67	0.89	0.11	81.9	1.65
RF2 pondéré	6.64	5.23	0.66	0.88	0.06	80.2	1.67
ARMAX	7.01	5.53	0.62	0.83	-2.77	96.1	1.76
Régression linéaire	7.62	5.38	0.55	0.79	-2.31	74.4	1.72
RF1	7.64	5.38	0.55	0.87	-3.01	75.0	1.72
RF3	7.70	6.60	0.54	0.88	2.44	98.5	2.10
RF4	7.86	6.80	0.52	0.89	3.46	99.1	2.17
ARIMA	9.79	7.72	0.26	0.81	-4.63	145.0	2.46
ARIMA corrigé	9.79	7.72	0.26	0.81	-4.63	145.0	2.46

Tableau 24: Annexe 22 — Tests de Diebold-Mariano complets

Comparaison	Statistique DM	p-value	Conclusion
RF2 vs Naïf	2.950	0.005	Différence significative
RF2 vs ARIMA	-3.700	0.001	Différence significative
RF2 vs ARIMA corrigé	-3.700	0.001	Différence significative
RF2 vs ARMAX	-0.692	0.492	Différence non significative
RF2 vs Régression linéaire	-0.848	0.401	Différence non significative
RF2 vs RF2 pondéré	-1.110	0.274	Différence non significative
RF2 vs RF2 rolling window	2.120	0.039	Différence significative
RF2 pondéré vs Naïf	2.960	0.005	Différence significative
RF2 rolling window vs Naïf	2.630	0.012	Différence significative
ARMAX vs Naïf	3.440	0.001	Différence significative
ARIMA corrigé vs ARIMA	NA	NA	Test impossible

Tableau 25: Annexe 23 — Principales erreurs du modèle RF2 classique

Date	Observé	Prévision	Erreur	Erreur absolue
2022-06	33.05	14.83	18.22	18.22
2022-07	28.50	14.80	13.70	13.70
2022-03	29.22	16.05	13.18	13.18
2022-05	27.84	14.83	13.00	13.00
2022-04	26.50	15.11	11.40	11.40
2025-02	-5.81	4.66	-10.47	10.47
2024-08	0.44	9.74	-9.30	9.30
2023-03	4.89	12.85	-7.96	7.96
2022-08	22.74	14.79	7.95	7.95
2023-06	-3.00	4.81	-7.82	7.82

Tableau 26: Annexe 24 — Principales erreurs du modèle RF2 rolling window

Date	Observé	Prévision	Erreur	Erreur absolue
2022-03	29.22	17.70	11.51	11.51
2023-03	4.89	15.50	-10.60	10.60
2025-02	-5.81	4.20	-10.00	10.00
2022-09	17.92	27.00	-9.03	9.03
2023-09	11.87	4.31	7.56	7.56
2022-06	33.05	26.17	6.88	6.88
2023-08	6.80	-0.01	6.80	6.80
2023-06	-3.00	3.77	-6.77	6.77
2022-08	22.74	28.96	-6.22	6.22
2022-12	15.12	21.06	-5.94	5.94

Tableau 27: Annexe 25 — Résumé des erreurs des modèles RF2 et RF2 rolling window

Modèle	Erreur moyenne	Erreur absolue moyenne	Erreur minimale	Erreur maximale	Écart-type des erreurs
RF2 classique	-0.11	5.18	-10.47	18.22	6.66
RF2 rolling window	-1.61	4.06	-10.60	11.51	4.73

Tableau 28: Annexe 26 — Robustesse du modèle RF2 sur 100 graines aléatoires

Indicateur	Moyenne	Minimum	Maximum	Écart-type
RMSE	6.70	6.52	6.90	0.08
MAE	5.25	5.03	5.47	0.08




Figure 20: Annexe 27 — Prévisions comparées des principaux modèles




Figure 21: Annexe 28 — Comparaison du RF2 classique et du RF2 rolling window




Figure 22: Annexe 29 — Erreurs de prévision du modèle RF2 rolling window




Figure 23: Annexe 30 — Erreurs de prévision du modèle RF2 classique

Table des matières

Remerciements	2
Résumé	3
Abstract	4
Glossaire des sigles et indicateurs	6
Introduction	7
Partie 1 : Inflation énergétique et marchés de l'énergie	11
1.1. Définition et intérêt économique de l'inflation énergétique	11
1.2. Mesure de l'inflation énergétique à partir de l'IPC énergie	12
1.3. Évolution récente de l'inflation énergétique en France	12
1.4. Justification économique des variables explicatives	15
1.5. Des relations économiques instables en période de chocs	18
1.6. Synthèse de la première partie	18
Partie 2 : Méthodologie de prévision	20
2.1. Objectif de la modélisation	20
2.2. Construction de la base et de la variable cible	20
2.3. Variables explicatives et variables retardées	21
2.4. Découpage apprentissage-test	22
2.5. Modèles de référence : modèle naïf, ARIMA et régression linéaire	23
2.6. Modèle linéaire dynamique : ARX et extension ARMAX	24
2.7. Modèle principal : Random Forest	26
2.8. Extensions méthodologiques : pondération, rolling window et robustesse	27
2.9. Indicateurs de performance et tests de comparaison	28
2.10. Synthèse de la démarche méthodologique	29
Partie 3 : Résultats empiriques et interprétation	31
3.1. Présentation de la base finale et analyse exploratoire	31
3.2. Comparaison globale des modèles de prévision	32
3.3. Interprétation du modèle naïf	33
3.4. Performances des modèles Random Forest	34
3.5. Apport du rolling window	35
3.6. Comparaison statistique des modèles : test de Diebold-Mariano	36
3.7. Analyse graphique des prévisions	37
3.8. Analyse des erreurs de prévision	38
3.9. Importance des variables dans la Random Forest	39
3.10. Robustesse des résultats	40
3.11. Synthèse des résultats empiriques	41

Discussion	43
Conclusion	47
Bibliographie	49
Ouvrages	49
Articles de revues scientifiques	49
Ressources internet	49
Packages R	50
Cours Master ECAP	51
Annexes	52
Annexe partie 1 : Environnement économique et présentation des variables	52
Annexe partie 2 : Démarche méthodologique et tests complémentaires	57
Annexe partie 3 : Résultats complémentaires et diagnostics de prévision	61