

# Note de synthèse

## Prévision de l'inflation énergétique en France : Random Forest en rolling window

### I. Résumé

Cette étude analyse la prévision de l'inflation énergétique en France sur données mensuelles, de juillet 2015 à septembre 2025. Dans un contexte marqué par le choc énergétique de 2022, plusieurs modèles sont comparés : naïf, ARIMA, ARMAX et Random Forest. L'approche retenue est une Random Forest en rolling window, qui réestime le modèle sur les données récentes afin de mieux suivre les changements de régime. Les résultats montrent que les retards de l'inflation et le prix du Brent sont les principaux prédicteurs, tandis que les chocs extrêmes restent difficiles à anticiper.

**Mots clés** : inflation énergétique, France, prévision, Random Forest, R.

### II. Problématique et cadre de l'étude

Depuis 2021, la France a connu une hausse exceptionnelle des prix de l'énergie. La reprise post-Covid, les tensions d'approvisionnement et l'invasion de l'Ukraine en février 2022 ont provoqué un choc énergétique majeur sur le marché européen du gaz (TTF) et sur le pétrole (Brent). L'inflation énergétique (mesurée en glissement annuel à partir de l'Indice des Prix à la Consommation énergie (INSEE)) a dépassé 30 % au printemps 2022, avant d'entamer une phase de désinflation progressive. Cette succession de régimes rend la série particulièrement difficile à modéliser avec des approches linéaires classiques.

**Problématique** : Peut-on prévoir l'inflation énergétique en France à partir des prix du pétrole, du gaz naturel et des matières premières, dans un contexte marqué par des chocs économiques et géopolitiques ?

Deux enjeux sont distingués : un enjeu prédictif, qui consiste à améliorer la précision de prévision hors échantillon, et un enjeu économique, qui vise à identifier les déterminants de marché les plus informatifs.

La base de données recouvre juillet 2015 à septembre 2025 (123 observations mensuelles). Le découpage apprentissage / test est chronologique : apprentissage sur juillet 2015 à décembre 2021, test sur janvier 2022 à septembre 2025. Ce choix place le choc énergétique de 2022 entièrement hors échantillon d'apprentissage, constituant ainsi un cadre d'évaluation particulièrement exigeant.

### III. Les données utilisées

Toutes les séries sont issues de l'INSEE et disponibles à fréquence mensuelle. Le tableau suivant résume les variables retenues :

| Variable                                                     | Rôle                   | Justification économique                                               |
|--------------------------------------------------------------|------------------------|------------------------------------------------------------------------|
| <b>Inflation énergie (IPC énergie)</b>                       | Variable cible         | Glissement annuel – variation des prix payés par les ménages           |
| <b>Brent en euros (retards 1 et 3 mois)</b>                  | Explicative principale | Déterminant direct des carburants, du fioul et des produits pétroliers |
| <b>Gaz naturel TTF (retards 1 et 3 mois)</b>                 | Explicative            | Prix de référence européen du gaz ; choc majeur 2021–2022              |
| <b>Matières premières hors énergie (retards 1 et 3 mois)</b> | Variable de contexte   | Tensions générales sur les marchés d'importation                       |
| <b>Retards de l'inflation (1, 3, 6, 12 mois)</b>             | Dynamique propre       | Capture l'inertie forte de la série en glissement annuel               |

Source : INSEE. Période : juillet 2015 – septembre 2025. Fréquence mensuelle.

On voit que le gaz naturel TTF présente une distribution très asymétrique sur la période (kurtosis = 11,7), avec des valeurs extrêmes concentrées sur 2021–2022. Par ailleurs, la transmission de ces prix de gros aux prix à la consommation a été partiellement amortie par le bouclier tarifaire mis en place par le gouvernement français, ce qui explique pourquoi cette variable n'améliore pas systématiquement la prévision malgré son importance conjoncturelle.

### IV. Méthodologie statistique

La Random Forest est une méthode d'apprentissage supervisé qui agrège les prévisions de plusieurs centaines d'arbres de décision. Chaque arbre est construit sur un sous-échantillon aléatoire des données et n'utilise qu'un sous-ensemble aléatoire de variables à chaque division. La prévision finale est la moyenne de l'ensemble des arbres. Cette agrégation réduit l'instabilité propre à un arbre unique et permet de capter des relations non linéaires et des interactions entre variables, sans supposer de forme fonctionnelle a priori.

L'apport central de cette étude repose sur la version rolling window. Plutôt que d'estimer le modèle une seule fois sur l'ensemble de la période d'apprentissage, le modèle est réestimé à chaque mois de la période de test en utilisant uniquement les 60 observations mensuelles les plus récentes. Cette fenêtre glissante permet au modèle de s'adapter aux changements de régime économique (notamment les retournements rapides observés pendant la crise énergétique et la désinflation) sans être alourdi par des observations trop anciennes. La fenêtre de 60 mois est choisie comme compromis entre représentativité statistique et réactivité conjoncturelle.

### Principe du rolling window – étapes pour chaque mois $t$ de la période de test :

1. Sélectionner les 60 observations mensuelles précédant  $t$ .
2. Entraîner une nouvelle Random Forest (500 arbres) sur cette fenêtre.
3. Produire la prévision pour  $t$  à partir des variables disponibles.
4. Avancer la fenêtre d'un mois et recommencer.

**Point important :** à chaque période, le modèle intègre les informations les plus récentes et « oublie » les régimes trop anciens.

Les performances sont évaluées par plusieurs indicateurs complémentaires : RMSE, MAE,  $R^2$  prédictif, corrélation et biais moyen. La significativité des écarts entre modèles est testée par le test de Diebold-Mariano, qui permet de vérifier si les différences d'erreurs de prévision sont statistiquement significatives et non dû au hasard. La robustesse est contrôlée en réestimant le modèle sur 100 graines aléatoires différentes.

## V. Résultats obtenus et commentés

Le tableau ci-dessous compare les performances des principaux modèles sur la période de test (de janvier 2022 à septembre 2025) :

| Modèle                    | RMSE        | MAE         | $R^2$       | Corr.       | Biais       |
|---------------------------|-------------|-------------|-------------|-------------|-------------|
| Naïf (référence)          | 4,05        | 3,10        | 0,87        | 0,94        | 0,51        |
| <b>RF2 rolling window</b> | <b>4,95</b> | <b>4,06</b> | <b>0,81</b> | <b>0,91</b> | <b>1,61</b> |
| RF2 classique             | 6,58        | 5,18        | 0,67        | 0,89        | 0,11        |
| ARMAX                     | 7,01        | 5,53        | 0,62        | 0,83        | -2,77       |
| ARIMA                     | 9,79        | 7,72        | 0,26        | 0,81        | -4,63       |

*Meilleur modèle complexe : RF2 rolling window. RMSE et MAE : plus faibles = meilleur.  $R^2$  et corrélation : plus élevés = meilleur.*




Figure 1: Prévisions comparées de l'inflation énergétique sur la période de test

Le modèle naïf est la référence à battre. Avec un RMSE de 4,05 et un  $R^2$  de 0,87, il surpasse tous les modèles complexes. Ce résultat n'est pas paradoxal car l'inflation calculée en glissement annuel est intrinsèquement persistante, car deux mois consécutifs partagent 11 mois d'information commune. Cette inertie rend la valeur passée immédiate très informative. Cela ne signifie pas

que les variables économiques sont inutiles, mais leur apport doit être évalué en dépassant cette référence exigeante.

La Random Forest rolling window est le meilleur modèle complexe. Avec un RMSE de 4,95 et un  $R^2$  de 0,81, elle améliore significativement la Random Forest classique (RMSE = 6,58). Ce gain est confirmé statistiquement par le test de Diebold-Mariano ( $p = 0,039$ ). L'adaptation progressive via la fenêtre glissante permet au modèle de mieux suivre les retournements, il réduit l'erreur absolue moyenne de 5,18 à 4,06 et diminue l'écart-type des erreurs de 6,66 à 4,73. Les erreurs les plus fortes restent concentrées sur les pics et retournements brutaux (mars 2022, mars 2023), qui correspondent à des ruptures difficiles à anticiper pour tout modèle statistique.

Les retards de l'inflation et le Brent sont les variables les plus prédictives. L'analyse d'importance (%IncMSE) désigne les retards de l'inflation et les retards du Brent comme les prédicteurs les plus utiles. En revanche, l'ajout du gaz TTF et des matières premières dégrade les performances de la Random Forest classique. Ces variables apportent du bruit en dehors de la crise de 2022, période durant laquelle leur transmission aux prix à la consommation a été partiellement neutralisée par le bouclier tarifaire.

Enfin, une analyse de robustesse sur 100 graines aléatoires confirme la stabilité des résultats du RF2 classique (RMSE moyen = 6,70, écart-type = 0,08), ce qui réduit le risque que les performances observées soient liées au hasard de l'initialisation.

## VI. Conclusion

La prévision de l'inflation énergétique reste un exercice difficile. Aucun modèle ne parvient à anticiper parfaitement les ruptures liées aux crises économiques et géopolitiques. La Random Forest rolling window constitue néanmoins la meilleure approche parmi les modèles complexes testés, en offrant une adaptation continue aux conditions économiques récentes. Elle améliore nettement la Random Forest classique et présente de meilleures performances que l'ARMAX, tout en restant en deçà du modèle naïf (ce qui rappelle que l'inertie de la série demeure la source d'information la plus robuste à court terme).

### Recommandations :

1. Toujours conserver le modèle naïf comme référence minimale dans tout dispositif de suivi de l'inflation énergétique.
2. Privilégier une estimation en rolling window pour les modèles de machine learning, afin qu'ils intègrent rapidement les retournements de conjoncture.
3. Interpréter les prévisions avec prudence en période de choc car les modèles statistiques doivent être utilisés comme outils d'appui et non de décision automatique.

## VII. Bibliographie

Medeiros M.C., Vasconcelos G.F.R., Veiga A. & Zilberman E. (2021). *Forecasting inflation in a data-rich environment: The benefits of machine learning methods*. Journal of Business & Economic Statistics, 39(1), 98–119.